

(注: 仅供参考, 请下载24小时内删除)

2012深圳杯B题 “手机用户识别”

(种子用户识别)

摘要

本文选取深圳市手机用户作为研究对象, 运用网络神采软件对 用户信息进行数据采集, 以研究短信领袖、话题用户、活跃用户和关系圈的识别问题。一、短信领袖: 本文采用了层次分析法和主成分分析法两种方法对短信领袖进行识别。层次分析法: 首先根据学术水平与信用等级、发短信数、回短信数与浏览数、精华短信数和威望这几个标准先对用户进行筛选, 针对影响用户成为短信领袖几个主要因素, 建立了层次分析模型, 运用 MATLAB 软件解出言论领袖。主成分分析: 先对所采的数据进行一系列的处理, 根据累计贡献率超过 80%筛选出 4 个主成分, 以主成分的方差贡献率为权数, 对这 4 个主成分得分进行加权, 利用 *Matlab* 程序, 算出一个综合得分, 得到一个短信领袖排序的结果, 综合两种方法, 得到最后短信领袖的结果为用手机号13976****987等的用户; 二、话题用户: 本文先对“数学建模”这个话题进行模糊处理, 得到关键词及关键词

的近义词所组成的集合, 选取深圳市手机用户为研究对象; 然后对某一时间段内的以“MATLAB 编程”为关键词的主题帖标题进行检索, 得到贴的集合; 最后, 对上述步骤所出现的用户组成集合, 取出现频数的均值, 高于均值的用户即“数学者”和“zhouzhihua”为可能的话题用户。

三、活跃用户: 本文运用模糊数学的原理建立两个模型, 通过对模型的综合比较得出活跃用户。模型一是先对论坛用户的各指标数据无量纲化处理后, 在进行模糊隶属度排序得到用户的隶属度活跃程度综合水平的高低排序; 模型二运用模糊聚类原理, 建立模糊优先矩阵, 通过 λ 截距阵法确定优先对象即得到活跃用户的排序, 最后综合上述两个模型最终得到132*****786, 136*****123等为活跃用户。

四、关系圈: 本文先选择论坛中的一个模块版主, 选取版主下面的 2 个用户, 提取他们所有发的短信以及所发的每篇短信的跟回短信用户等数据信息; 运用上述软件确定回短信 用户出现的次数, 统计得在多条短信中出现的用户即为该用户的关系圈。同时因为关系圈的复杂性, 本文用另一个方法确定某个用户的关系圈。先对论坛中的某一话题模块运用上述话题用户的识别方法, 得到 M 位话题用户, 并对其进行活跃用户的识别; 再根据隶属度 μ 的大小进行排序, 剔除活跃度低于平均数的用户, 筛选后得到的用户即可划为该话题的关系圈。

1、问题重述

中国移动手机发展经历了 10 年的快速增长期，已经形成较为成熟的应用。现在的手机正从信息单向推送模式向互动模式转型，手机已经成为互联网企业与用户、用户与用户之间重要的互动平台。

在这样的互动氛围中衍生出了很多商业机会和运营难题。为回答这些问题和解决运营难题，企业需对网内内的用户进行有效识别。

主要解决以下四个识别问题：

- 1、短信领袖：从所发短信的回短信数量、精华短信、保存时间、短信总数等变量切入，发掘短信领袖并进行综合评价；
- 2、话题用户：从主要短信主题、内容判断话题用户
- 3、活跃用户：从使用频率、参与话题数量等方面识别活跃用户并进行综合评价；
- 4、关系圈：从短信关联关系等方面发掘短信人际关系圈并进行综合评价。

2、基本假设

- 1、主成分分析中，确定主成分的要求是累计贡献率达到 80%；
- 2、假设本文中提取的手机用户信息不随时间的变化而改变；
- 3、假设在对短信领袖的识别中不存在垃圾短信等现象。

3、符号说明

RI	平均随机一致性指标	$\tilde{F}$	模糊指标矩阵
CI	一致性指标	$\tilde{w}$	权重向量
$\tilde{M}$	模糊负理想	$\tilde{D}$	模糊决策矩阵
μ_i	隶属度	$\tilde{M}^+$	模糊正理想

4、模型的建立与求解

4.1 短信领袖

4.1.1 方法一 ——层次分析法模型： 言论领袖是最具影响力的论坛人物,在言论领袖的确定中,本文考虑到的是访问量、

跟帖数、精华帖数、发帖总数、主题数和威望这几个因素。本文根据以下方法对数据处理后可以得到 m 个用户的 n 项指标的数据,然后再运用层次分析法从 m 个用户中选出言论领袖.

4.1.2 设定的评判标准如下：

(1) 学术水平与信用等级 学术水平与信用等级是用户对贴主的解答的专业程度等做出的评价。我们根据学术水平与信用等级均不小于 20 点进行第一步筛选, 剔除部分用户。

(2) 发帖数 用户在论坛上的发帖数的多少是衡量的基本标准。我们根据用户的发帖数与总体发帖数之间的比值, 剔除掉一些比值太小的用户。

(3) 主题数 主题数即由某人引起的话题的数目。一个能提出好的主题并且吸引很多人浏览甚至跟帖的贴主成为言论领袖的概率比较大。排除掉那些没有提出主题数的用户。

(4) 跟帖数与浏览数 在发表的帖子后面, 写上自己的意见, 称为跟帖, 也叫回帖。一篇论坛贴跟帖数的多少是该帖子所引起的讨论热度以及被关注程度的直接反映。当浏览数与跟帖数的比值太大, 说明该帖有哗众取宠的嫌疑, 不可能成为言论领袖; 当浏览数与跟帖数的比值太小时, 有灌水的可能。所以在本文中剔除掉其比值较小的用户。

(5) 精华帖数 精华贴是论坛中的一种帖子种类, 是被版主或管理员加为精华的帖子, 一般此类帖子内容丰富, 有较高的阅读价值。精华帖更具优越性, 在评定话题用户中占重要比重。

(6) 威望 论坛威望是指该用户在论坛的交往能力, 魅力指数。威望越多说明该用户在论坛内的人气越高、交往能力越强, 魅力值越高。为了简化数据的繁杂性, 在数据的整理中我们添加威望指标, 剔除掉威望值较小的用户, 这样就简化得到更优的数据。通过 <http://www.pinggu.org/bbs/> 网站我们运用网络神采软件 (采集过程见附录 4) 对论坛信息进行数据的挖掘。由于考虑到计算过程的繁琐, 本文特此选取其中 15 位用户 (标号 1~15) 进行评价, 如表 1 所示:

表 1 筛选出的 15 名论坛用户信息

序号	用户名	帖子数	发帖比例	访问量	跟帖数	跟帖/访问	精华	威望	主题	学术水平	信用等级
1	经济门外溜达	1521	0.020%	600	86	0.143333	1	0	0	106点	75点
2	xiaoz	566	0.007%	1298	598	0.460709	2	6	9	60点	65点
3	青山客	5149	0.068%	21545	1567	0.072731	2	4	15	54点	22点
4	沙漏	830	0.011%	756	13	0.017196	0	0	0	10点	10点
5	犀利哥	1265	0.017%	389	85	0.218509	1	3	1	22点	21点
6	两元鱼	726	0.010%	2319	79	0.034066	0	0	5	32点	33点
7	zeroman n	45	0.001%	349	9	0.025788	1	0	1	23点	23点

8	来无影 去无踪	601	0.008%	1637	148	0.090409	0	0	4	30点	16点
9	老猫	119	0.002%	308	0	0	1	0	0	48点	48点
10	ear on head	241	0.003%	579	34	0.058722	0	0	0	2 点	2 点
11	叉尔施	25	0.0003%	213	0	0	1	0	0	11点	10点
12	诺言	93	0.001%	582	42	0.072165	0	0	1	0 点	0 点
13	三公子	4232	0.056%	31967	1067	0.033378	0	8	11	24点	21点
14	枫	1111	0.015%	12673	619	0.048844	0	6	9	47点	32点
15	之语嘛	1808	0.024%	25539	72	0.002819	1	13	20	96点	76点

表 1

由以上叙述的方法,根据学术水平与信用等级均不小于 20 点进行第一步筛选,剔除用户 4、8、10、11、12。再根据发帖数的多少进一步筛选,剔除掉比例小于 0.005%的用户 7、9;对未提出讨论主题并且跟帖数与浏览数小于 0.03 的用户进行排除 1、15;对剩下的用户继续筛选,排除掉威望指小于 3 的用户 6;得到最后相对有可能成为言论领袖的用户 2、3、5、13 和 14. 下面用层次分析法分析得到最权威的言论领袖。

将上述 5 个用户重新编号,根据上面方法对数据处理后得到 5 个用户的 5 项指标的数据,然后再运用层次分析法从 5 个用户中选出言论领袖,如表 2 所示:

表 2 可能成为言论领袖的 5 名论坛用户信息

用户 序号	用户名	帖子数	访问量	跟帖数	威望	主题
1	xiaoz	566	1298	598	6	9
2	青山客	5149	21545	1567	4	15
3	犀利哥	1265	389	85	3	1
4	三公子	4232	31967	1067	8	11
5	枫	1111	12673	619	6	9

表 2

4.1.3 模型的建立:

1)、建立递阶层次结构模型,在此问题中,根据主题、精华帖数、跟帖数、访问量和威望 5 个准则去反复比较 5 个候选网上用户,如图 1 所示:




图 1

2)、构造出各层次中的所有判断矩阵,采取对因子进行两两比较建立成对比较矩阵的办法.即每次取两个因子 x_i 和 x_j ,以 a_{ij} 表示 x_i 和 x_j 对 Z 的影响大小之比,全部比较结果用矩阵 $A=[a_{ij}]$ 表示,称 A 为 Z 与 X 之间的成对比较判断矩阵(简称判断矩阵).容易看出,若 x_i 与 x_j 对 Z 的影响之比为 a_{ij} ,则 x_j 与 x_i 对 Z 的影响之比应为

$$a_{ji} = \frac{1}{a_{ij}}.$$

并引用数字 1~9 及其倒数作为标度,如表 3 所示:

表 3 1~9 标度的含义

标度	含 义
1	表示两个因素相比,具有相同重要性
3	表示两个因素相比,前者比后者稍重要
5	表示两个因素相比,前者比后者明显重要
7	表示两个因素相比,前者比后者强烈重要
9	表示两个因素相比,前者比后者极端重要
2, 4, 6, 8	表示上述相邻判断的中间值
倒数	若因素i与因素j的重要性之比为a_{ij},那么因素j与因素i重要性之比为 $a_{ji} = \frac{1}{a_{ij}}.$

表 3

比较多个因子对某个因素的重要性的判断依据:

准则层对目标层的判断依据：经过网上试卷调查及咨询专业人士. 可以构造主题、精华帖数、跟贴数、访问量和威望 5 个对言论领袖的重要性判断矩阵, 如表 4 所示：

表 4 准则层

O	C_1 主题	C_2 精华贴数	C_3 跟贴数	C_4 访问量	C_5 威望
C_1 主题	1	1/7	1/3	1/2	1/5
C_2 精华贴数	7	1	3	5	3
C_3 跟贴数	3	1/3	1	3	1
C_4 访问量	2	1/5	1/3	1	1/5
C_5 威望	5	1/3	3	5	1

表 4

措施层对准则层的判断依据：根据我们在网站统计的相关项目的数目来比较, 用户信息如表 2 所示. 类似地, 分别比较五个候选用户的主题、精华帖数、跟贴数和浏览数得成对比较阵, 如表 5 所示：

表 5 方案层

C_1	P_1	P_2	P_3	P_4	P_5
P_1	1	1/5	5	1/3	1/2
P_2	5	1	9	3	5
P_3	1/5	1/9	1	1/7	1/5
P_4	3	1/3	7	1	3
P_5	2	1/5	5	1/3	1

C_2	P_1	P_2	P_3	P_4	P_5
P_1	1	1/7	1/3	1/5	1/3
P_2	7	1	5	3	5
P_3	3	1/5	1	1/3	1/2

P_4	5	1/3	3	1	3
P_5	3	1/5	2	1/3	1

C_3	P_1	P_2	P_3	P_4	P_5
P_1	1	1/5	3	1/3	1/2
P_2	5	1	7	3	5
P_3	1/3	1/7	1	1/5	1/3
P_4	3	1/3	5	1	3
P_5	2	1/5	3	1/3	1

C_4	P_1	P_2	P_3	P_4	P_5
P_1	1	1/5	3	1/7	1/3
P_2	5	1	7	1/3	3
P_3	1/3	1/7	1	1/9	1/5
P_4	7	3	9	1	5
P_5	3	1/3	5	1/5	1

C_5	P_1	P_2	P_3	P_4	P_5
P_1	1	3	5	1/3	1/2
P_2	1/3	1	3	1/5	1/3
P_3	1/5	1/3	1	1/7	1/5
P_4	3	5	7	1	3
P_5	2	3	5	1/3	1

3)、层次单排序及一致性检验:

判断矩阵 A 对应于最大特征值 $\lambda_{\max}$ 的特征向量 W , 经归一化后即为同一层次相应因素对于上一层次某因素相对重要性的排序权值, 这一过程称为层次单排序. 即: 若 A 的最大特征值 $\lambda_{\max}$ 对应的特征向量为 $W = (w_1, \dots, w_n)^T$, 则

$$q_j = \frac{w_i}{w_j}, i, j=1, 2, \dots, n,$$

即

$$A = \begin{pmatrix} \frac{w_1}{w_1} & \frac{w_1}{w_2} & \dots & \frac{w_1}{w_n} \\ \frac{w_2}{w_1} & \frac{w_2}{w_2} & \dots & \frac{w_2}{w_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{w_n}{w_1} & \frac{w_n}{w_2} & \dots & \frac{w_n}{w_n} \end{pmatrix}$$

对判断矩阵的一致性检验的步骤如下:

(i) 计算一致性指标 CI :

$$CI = \frac{\lambda_{\max} - n}{n - 1}$$

(ii) 查找相应的平均随机一致性指标 RI . 对 $n=1, \dots, 9$, RI 的值, 如表 6 所示:

表 6 一致性指标 RI 值

n	1	2	3	4	5	6	7	8	9
RI	0	0	0.58	0.90	1.12	1.24	1.32	1.41	1.45

表 6

RI 的值是这样得到的, 用随机方法构造 500 个样本矩阵: 随机地从 1~9 及其倒数中抽取数字构造正互反矩阵, 求得最大特征根的平均值 $\lambda'_{\max}$, 并定义

$$RI = \frac{\lambda'_{\max} - n}{n - 1} \cdot RI = 1.12$$

(iii) 计算一致性比例 CR

$$CR = \frac{CI}{RI} = \frac{\lambda_{\max} - n}{\lambda'_{\max} - n}$$

当 $CR < 0.10$ 时, 认为判断矩阵的一致性是可以接受的, 否则应对判断矩阵作适当修正.

4)、层次总排序及一致性检验. 上面我们得到的是一组元素对其上一层中某元素的权重向量. 我们最终要得到各元素, 特别是最低层中各方案对于目标的排序权重, 从而进行方案选择. 总排序权重自上而下地将单准则下的权重进行合成.

当准则层包含 $A_1, \dots, A_m$ 共 m 个因素, 它们的层次总排序权重分别为 $a_1, \dots, a_m$. 措施层包含 n 个因素 $B_1, \dots, B_n$, 它们关于 A_j 的层次单排序权重分别为 $b_{1j}, \dots, b_{nj}$ (当 B_i 与 A_j 无关联时, $b_{ij} = 0$). 现求 B 层中各因素关于总目标的权重, 即求措施层各因素的层次总排序权重 $b_1, \dots, b_n$, 计算如表 7 所示方式进行, 即

$$b_i = \sum_{j=1}^m b_{ij} a_j, \quad i = 1, \dots, n.$$

表 7 层次总排序权重

A B	A_1 a_1	A_2 a_2	$\dots$ $\dots$	A_m a_m	B 层总进展 权值
B_1	b_{11}	b_{21}	$\dots$	b_{n1}	$\sum_{j=1}^m b_{1j} a_j$
B_2	b_{12}	b_{22}	$\dots$	b_{n2}	$\sum_{j=1}^m b_{2j} a_j$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
B_n	b_{1n}	b_{2n}	$\dots$	b_{nn}	$\sum_{j=1}^m b_{nj} a_j$

表 7

对层次总排序作一致性检验: 设 B 层中与 A_j 相关的因素的成对比较判断矩阵在单排序中经一致性检验, 求得单排序一致性指标为 $CI(j)$, ($j = 1, \dots, m$), 相应的平均随机一致性指标为 $RI(j)$ ($CI(j)$ 、 $RI(j)$ 已在层次单排序时求得), 则 B 层总排序随机一致性比例

$$CR = \frac{\sum_{j=1}^m CI(j) a_j}{\sum_{j=1}^m RI(j) a_j}$$

当 $CR < 0.10$ 时, 认为层次总排序结果具有较满意的一致性并接受该分析结果. 根据以上利用 MATLAB 软件进行求解 (程序见附录 1), 得到表 8 的如下结果:

表 8 层次总排序

准则		主题	精华贴数	跟帖数	访问量	威望	总排序 权值
准则层权值		0.0484	0.4621	0.1424	0.0694	0.2778	
方案层 单排序 权值	用户 1	0.0951	0.0454	0.0902	0.0634	0.1760	0.0917
	用户 2	0.5009	0.5011	0.5011	0.2615	0.0849	0.3688
	用户 3	0.0318	0.0902	0.0454	0.0333	0.0421	0.0637
	用户 4	0.2471	0.2442	0.2442	0.5128	0.4646	0.3242
	用户 5	0.1251	0.1191	0.1191	0.1290	0.2323	0.1515

表 8

由此可知,用户的影响力排名为:

用户 2>用户 4>用户 5>用户 1>用户 3 即青山客>三公子>枫>xiaoz>犀利哥
显然,用户 2 即青山客为论坛的言论领袖.

4.1.4 方法二——主成分分析法模型 主成分分析将具有一定相关性的众多指标重新组合成新的无相互关系的综合指标

来代替。通常数学上的处理就是将这 P 个指标进行线性组合作为新的综合指标。

现有 15 位人大经济论坛用户,根据帖子数、浏览次数、跟帖数、精华、经验、威望、学术水平、信用等级、在线时间和主题等相关各条件得到最佳的论坛领袖成员的识别方案。因为考虑的因素很多,可以采用主成分分析法对其简化。

4.1.5 数据标准化:

对原始数据进行标准化处理。现有15位人大经济论坛用户,每人共有10个评定因素, a_{ij} (量纲不同,数值差别较大,使得各个指标的作用常难于比较,因此需要

$i=1,2,\dots,15; j=1,2,3,\dots,10$) 为第 i 个人员的第 j 个评价指标, 标准化计算公式如下:

$$X_{ij} = \frac{Z_{ij} - \bar{Z}_j}{S_j}, i=1,2,\dots,15; j=1,2,3,\dots,10$$

其中:

$$S_j^2 = \frac{1}{15} \sum_{i=1}^n (Z_{ij} - \bar{Z}_j)^2, j=1,2,3,\dots,10$$

$$\bar{Z}_j = \frac{1}{15} \sum_{i=1}^{15} Z_{ij}$$

利用 *Matlab* 程序标准化数据 x , 利用 *cov* 函数求出协方差矩阵, 进一步利用 *eig* 函数对求得的协方差矩阵求得特征根, 又根据假设主成分的选定需要影响因素累计贡献率大于百分之八十, 于是得到四个符合假设的主成分的特征根:

$$d_1 = 4.84 \quad d_2 = 2.10 \quad d_3 = 1.65 \quad d_4 = 0.70$$

由上面的数据我们可以得到 (d_1, d_2, d_3, d_4) 的累计贡献率达到了 $92.92\% > 80\%$ 以主成分的方差贡献率为权数, 对这四个主成分得分进行加权, 利用 *Matlab* 程序。算出一个

综合得分，得到的结果，即15位人大经济论用户的领袖排序

领袖排名	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
用户序号	13	15	3	14	2	1	6	5	8	9	11	4	10	7	12

4.1.6 两种方法的结果差异分析： 方法一领袖排序的结果：青山客>三公子>枫>xiaoz>犀利哥 方法二领袖排序的结果：三公子>之语嘛>青山客>枫>xiaoz 根据上述结果可知，由层次分析法和主成分分析法所得的领袖前 5 名的用户基本相同，即说明上述两个模型通过相互检验，对确定论坛领袖具有可行性。而排名的顺序不同，经分析知，导致其不同的原因是所考虑的影响因素的不同。
综上所述，论坛领袖为“青山客”和“三公子”。

4.2 话题用户

4.2.1 模型的建立与求解： 关注某一话题的用户的定位从其跟帖的主题、谈论内容来判断, 设定话题名以及与话题名有关的词语为关键词. 利用 MATLAB 编程搜索一篇跟帖中出现话题关键词的频数来判定该用户是否为话题用户. 步骤如下：

步骤一：确定所讨论话题的关键词及近义词
选定一个讨论话题, 使用 google 或者百度的模糊搜索功能确定出和所讨论话题相关的关键词及关键词的近义词, 设关键词及关键词的近义词所组成的集合为 $\{a_1, a_2, \dots, a_n\}$. 例如, 当选定数学建模话题时, 通过 google 模糊搜索找出的关键词及关键词的近义词所组成的集合为 {数学建模, 数学建模优秀论文, 数学中国, ...}.

步骤二：对某一时间段内的主题帖标题进行检索, 找出包含所讨论话题关键词及近义词的主贴, 包含话题关键词及近义词的主贴的集合为 $\{b_1, b_2, \dots, b_m\}$, MATLAB 编程（见附录 1）

步骤三：对步骤二中所出现的用户组成集合 $\{c_1, c_2, \dots, c_l\}$, 对确定出的主题帖中的用户进行排序, 取出现频数的均值, 高于均值的用户即为可能的话题用户。

话题用户的识别实例：
利用步骤二对数学中国网站的资源专区：<http://www.madio.net/forum-110-1.html> 关于 MATLAB 编程筛选出 5 个关于该话题的主题帖，1、MATLAB 编程基础；2、MATLAB 编程语言风格；3、nlinfit 请教 MATLAB 编程问题；4、预防性维修周期的 MATLAB 编程；5、MATLAB 编程源代码。筛选出只出现在一个主题帖的用户，统计出现在五个主题帖的用户次数排序如表 9：

表 9 主题帖的跟帖用户次数排序

用户名	数学者	zhouzhihua	pangheming	linmatsas	Lzhml9	少将师长
次数	5	5	3	3	2	2

由此可以看出数学者和 zhouzhihua 最可能是关注 MATLAB 编程的话题用户。

4.3 活跃用户的识别

4.3.1 方法一

1.1 根据数据采集器从人大经济论坛得到的数据，对筛选出的 15 位论坛用户（见表 10），根据热心指数、经验、在线时间和帖子数四个方面进行考量，用模糊数学的原理对他们进行活跃度的识别，再根据得到的隶属度的高低来得到这 15 位用户进行一个活跃度的排序，对他们进行识别。

表 10 筛选的 15 名用户信息

序号	用户名	热心指数	经验	在线时间	帖子
1	经济门外溜达	178	17409 点	836 小时	1521
2	xiaoz	124	8672 点	284 小时	566
3	青山客	54	4961 点	1577 小时	5149
4	沙漏	3	768 点	56 小时	830
5	犀利哥	27	7085 点	881 小时	1265
6	两元鱼	55	2542 点	177 小时	726
7	zeromann	21	1264 点	79 小时	45
8	来无影去无踪！	41	1158 点	415 小时	601
9	老猫	43	2340 点	78 小时	119
10	ear on head	2	2566 点	91 小时	241
11	叉尔施·稀奇	2	1132 点	16 小时	25
12	诺言	0	1086 点	85 小时	93
13	三公子	58	62178 点	2533 小时	4232
14	枫	100	21968 点	233 小时	1111
15	之语嘛	24	8005 点	2170 小时	1808

表 10

1.2 对于定性指标值 A, B, C, D, 可以定义量化标准将这些定性指标进行量化, 其具体的量化形式见表 11.

表 11 定性指标量化标准

评价指标等级	A	B	C	D
量化模糊数	(85, 90, 100)	(75, 80, 85)	(60, 70, 75)	(50, 55, 60)

表 11

其中 A, B, C, D 四个等级的评判如表 12 所示:

表 12 各等级的判断标准

	A	B	C	D
热心指数	100~	60~100	30~60	0~30
经验	30000~	10000~30000	1000~10000	0~1000
在线时间(h)	1000~	500~1000	100~500	0~100
帖子	4000~	1500~4000	500~1500	0~500

表 12

按照评定标准, 根据表的定性指标量化标准, 得到下列矩阵:

1.3 由已知条件, 将指标信息、权重信息化成三角形模糊数, 得到矩阵 F 和 w , 在这

里,我们认定四个指标权重相等.

1.4 在 $\tilde{F}$ 中对应应有 n 个模糊指标值, 记为 $\tilde{x}_i = (a_i, b_i, c_i)$, $(i=1, 2, \dots, n)$. 将 $\tilde{x}$ 进行归一化的具体公式如下:

$$\tilde{y}_i = \left(\frac{a_i}{\max(a_i)}, \frac{b_i}{\max(b_i)}, \frac{c_i}{\max(c_i)} \right) \in [0, 1]$$

设归一化后的模糊指标矩阵 $\tilde{R} = (\tilde{y}_{ij})_{m \times n}$.

1.5 将归一化后的模糊指标矩阵 $\tilde{R}$ 进行加权处理可得到模糊决策矩阵 $\tilde{D} = (\tilde{r}_{ij})_{m \times n}$, 其中

$$\tilde{r}_{ij} = \tilde{w} \oplus \tilde{y}_{ij} \quad (i=1, 2, \dots, m, j=1, 2, \dots, n)$$

运用 MATLAB 软件进行求解 (程序见附录 2) 得:

$$D = \begin{bmatrix} 0.2125 & 0.0625 & 0.2125 & 0.15 & 0.0625 & 0.15 & 0.1875 & 0.0625 & 0.1875 & 0.15 & 0.0625 & 0.15 \\ 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 & 0.2125 & 0.0625 & 0.2125 & 0.15 & 0.0625 & 0.15 \\ 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 & 0.15 & 0.0625 & 0.15 \\ 0.125 & 0.0625 & 0.125 & 0.15 & 0.0625 & 0.15 & 0.1875 & 0.0625 & 0.1875 & 0.15 & 0.0625 & 0.15 \\ 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 \\ 0.125 & 0.0625 & 0.125 & 0.15 & 0.0625 & 0.15 & 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 \\ 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 & 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 \\ 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 & 0.15 & 0.0625 & 0.15 \\ 0.125 & 0.0625 & 0.125 & 0.15 & 0.0625 & 0.15 & 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 \\ 0.125 & 0.0625 & 0.125 & 0.15 & 0.0625 & 0.15 & 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 \\ 0.125 & 0.0625 & 0.125 & 0.15 & 0.0625 & 0.15 & 0.125 & 0.0625 & 0.125 & 0.125 & 0.0625 & 0.125 \end{bmatrix}$$

$$1.6 \quad \text{设 } \tilde{M}^+ = (\tilde{M}_1^+, \tilde{M}_2^+, \dots, \tilde{M}_n^+), \quad \tilde{M}^- = (\tilde{M}_1^-, \tilde{M}_2^-, \dots, \tilde{M}_n^-),$$

其中分量 $\tilde{M}_j^+ = \max\{\tilde{r}_{1j}, \tilde{r}_{2j}, \dots, \tilde{r}_{nj}\}$ ($j=1, 2, \dots, n$) 是模糊决策矩阵 $\tilde{D}$ 中指标 j 的模糊指

标值所对应的模糊极大集; $\tilde{M}_j^- = \min\{\tilde{r}_{1j}, \tilde{r}_{2j}, \dots, \tilde{r}_{nj}\}$ ($j=1, 2, \dots, n$) 是模糊决策矩阵 $\tilde{D}$

中指标 j 的模糊指标值所对应的模糊极小集, 运用 MATLAB 软件进行求解 (程序见附录 2) 得

$$\overline{M}^+ = [0.2125 \ 0.0625 \ 0.2125 \ 0.2125 \ 0.0625 \ 0.2125 \ 0.2125 \ 0.0625 \ 0.2125 \ 0.2125 \ 0.0625 \ 0.2125]$$

$$\overline{M}^- = [0.125 \ 0.0625 \ 0.125 \ 0.125 \ 0.0625 \ 0.125 \ 0.125 \ 0.0625 \ 0.125 \ 0.125 \ 0.0625 \ 0.125]$$

1.7 确定评价对象*i*与模糊正负理想 $\tilde{M}^+$ 、 $\tilde{M}^-$ 之间的距离 d_i^+ 、 d_i^- :

$$d_i^+ = \sqrt{\sum_{j=1}^4 [d(\tilde{r}_{ijL}, \tilde{M}_{jL}^+) + d(\tilde{r}_{ijR}, \tilde{M}_{jR}^+)]^2}, \quad i=1, 2, \dots, n$$

$$d_i^- = \sqrt{\sum_{j=1}^4 [d(\tilde{r}_{ijL}, \tilde{M}_{jL}^-) + d(\tilde{r}_{ijR}, \tilde{M}_{jR}^-)]^2}, \quad i=1, 2, \dots, n.$$

1.8 模糊优选决策

设评价对象*i*以隶属度 μ_i 从属于模糊正理想, 则

$$\mu_i = \frac{(d_i^-)^2}{(d_i^+)^2 + (d_i^-)^2} \quad (i=1, 2, \dots, n)$$

按隶属度 μ_i 从大到小进行排序. μ_i 越大, 表示评价对象*i*越优. 最后按隶属度的确定评价对象的优劣.

求出相应的 d_i^+ 、 d_i^- 、 μ_i ($i=1, 2, \dots, 16$), 运用 MATLAB 软件进行求解 (程序见附录 2), 结果如表 13 所示:

表 13 15 名用户的排序结果

序号	用户名	模糊正理想 d_i^+	模糊负理想 d_i^-	隶属度 μ_i
1	经济门外溜达	0.061237	0.19685	0.91176
2	xiaoz	0.1299	0.16008	0.60294
3	青山客	0.15309	0.13807	0.44853
4	沙漏	0.23184	0.035355	0.022727
5	犀利哥	0.17941	0.10155	0.24265
6	两元鱼	0.17678	0.070711	0.13793
7	zeromann	0.23184	0.035355	0.022727
8	来无影去无踪	0.21506	0.05	0.051282
9	老猫	0.17678	0.070711	0.13793
10	ear on head	0.23184	0.035355	0.022727
11	叉尔施·稀奇	0.23184	0.035355	0.022727
12	诺言	0.23184	0.035355	0.022727
13	三公子	0.088388	0.21723	0.85795
14	枫	0.1299	0.16008	0.60294
15	之语嘛	0.15612	0.15612	0.5

表 13

由以上结果可知, 15 个网络论坛用户的活跃程度综合水平的高低排序为:

$$u_1 > u_{13} > u_2 = u_{14} > u_{15} > u_3 > u_5 > u_6 = u_9 > u_8 > u_4 = u_{10} = u_{11} = u_{12} = u_7$$

可见, 论坛用户 1、用户 13、用户 2、用户 14、用户 15 等为活跃用户。

4.3.2 方法二

利用模糊数学中的模糊决策原理来对以上 15 位论坛用户进行识别。与上一个模型不同的是该模型利用优先关系进行活跃度排序。

模糊排序

设论域 $U = \{x_1, x_2, x_3, \dots, x_{15}\}$ 是被分类的对象，每个对象又由 4 个指标表示其形状，

即 $x_i = \{x_{i1}, x_{i2}, x_{i3}, x_{i4}\}$

于是，可得原始数据矩阵 $X = (x_{ij})_{15 \times 4}$

$$\begin{array}{cccc} \square & x_{11} & x_{12} & \cdots & x_{14} & \square \\ \square & x_{21} & x_{22} & \cdots & x_{24} & \square \\ \square & \vdots & \vdots & & \vdots & \square \\ \square & x_{151} & x_{152} & \cdots & x_{154} & \square \end{array}$$

1)、第一步：进行数据的标准化处理——利用标准差变换法：

$$x'_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \quad \text{其中 } \bar{x}_j = \frac{1}{15} \sum_{i=1}^{15} x_{ij}$$

$$s_j = \sqrt{\frac{1}{15} \sum_{i=1}^{15} (x_{ij} - \bar{x}_j)^2}$$

经过计算得：

$$\text{热心指数: } s_1 = 0.2000 \quad \bar{x}_1 = 48.8$$

$$\text{经验: } s_2 = 0.5164 \quad \bar{x}_2 = 9542$$

$$\text{在线时间: } s_3 = 0.2582 \quad \bar{x}_3 = 634$$

$$\text{帖子: } s_4 = 0.0177 \quad \bar{x}_4 = 1222.1$$

得到变化后的矩阵为：

$$\psi_2 = \begin{pmatrix} 646 & 16890 & 15230 & 782 & / \\ 376 & -37070 & -1680 & -1356 & \infty \\ 26 & 221860 & -8870 & 3652 & \infty \\ -229 & -22150 & -16990 & -2239 & \infty \\ -109 & 2420 & -4760 & 957 & \infty \\ 31 & -28030 & -13560 & -1770 & \infty \\ -139 & -66500 & -16030 & -2150 & \infty \\ -39 & -35090 & -16240 & -848 & \infty \\ -29 & -62320 & -13950 & -2153 & \infty \\ -234 & -55430 & -13510 & -2103 & \infty \\ -234 & -67630 & -16290 & -2394 & \infty \\ -244 & -63790 & -16370 & -2126 & \infty \\ 46 & 170050 & 101930 & 7355 & \infty \\ 256 & -6280 & 24060 & -1553 & \infty \\ \leq -124 & 36490 & -2980 & 5949 & \infty \end{pmatrix}$$

2)、第二步：建立模糊相似矩阵

设论域 $U = \{x_1, x_2, x_3, \dots, x_{15}\}$, $x_i = \{x_{i1}, x_{i2}, x_{i3}, x_{i4}\}$, 如果 x_i 与 x_j 之间的相似程度为

$r_{ij} = R(i, j)$, 则称之为相似系数。 $R = (r_{ij})_{n \times n}$ 为相似系数矩阵

本文利用相关系数法确定相似系数:

$$r_{ij} = \frac{\left| \sum_{k=1}^m (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j) \right|}{\sqrt{\sum_{k=1}^m (x_{ik} - \bar{x}_i)^2 \sum_{k=1}^m (x_{jk} - \bar{x}_j)^2}}$$

利用 *matlab* 中的 *corrcoef* 函数对 ψ 求相关系数: $cor = \text{corrcoef}(\psi)$

得到模糊相似矩阵 R (见附录 3)

3)、第三步：进行优先排序

从第二步求出的 n 阶模糊相似矩阵 R 出发, 用平方法求其传递闭包 $t(R)$, 它就是

将 R 改造成的 n 阶模糊等价矩阵, 再将矩阵 R 转换为 λ -截矩阵 R_λ 是 n 阶等价布尔矩阵。再让 λ 从 1 由大变小为 0, 就可形成动态聚类图。

求传递闭包 $t(R)$ 的原理: 不断将 R 平方, 当第一次出现 $R^k R^k = R^k$

时, R^k 即为所求。

本文求得了 R^k 的近似矩阵为 χ (见附录 3)

利用λ截矩阵法对χ中的向量（即代表的人大经济论坛用户）进行排序

排序方法：取定阈值λ [0,1]得λ截矩阵 $R_{\lambda} = (r_{ij}(\lambda))_{n \times n}$

当λ由 1 逐渐下降时,若 R_{λ} 中首次出现第 k 行的元素全等于 1 时,则认定 x_k 是第一优先对象(不一定唯一). 再在 R 中划去 x_k 所在的行与列,得到一个新的 $n-1$ 阶模糊优先矩阵,用同样的方法获取的对象作为第二优先对象；如此进行下去,可将全体对象排出一定的优劣次序.

当λ=0.7时得到的 R_{λ} 矩阵可以得到：

$R_{\lambda} =$

1	1	1	1	1	1	1	1	1	1	1	1	1	1	1/2
1	1	1	1	0	1	1	1	1	1	1	1	1	1	1/2
0	1	1	0	0	1	1	1	1	1	1	1	1	1	1/2
1	1	0	1	0	1	1	1	1	1	1	1	1	0	0/2
0	0	0	0	1	0	0	0	0	0	0	0	0	1	1/2
1	1	1	1	0	1	1	1	1	1	1	1	1	0	1/2
1	1	1	1	0	1	1	1	1	1	1	0	1	0	1/2
1	1	1	1	0	1	0	1	0	1	1	0	1	0	1/2
1	1	1	1	0	1	1	1	1	1	1	1	1	0	1/2
1	1	1	1	0	1	1	1	1	0	1	1	1	0	1/2
1	1	1	1	0	1	1	0	1	1	1	1	1	1	1/2
1	1	1	1	1	1	1	1		1	1	1	1	1	1/2
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1/2
1	1	1	1	1	1	1	1	1	0	0	0	0	1	1/2
0	1	0	0	1	1	1	1	1	1	1	1	1	0	1/2

由上图得到 x_1 和 x_{13} 是活跃程度最高的用户，根据得到的矩阵再根据λ的变化得到其他的矩阵，最后得到的活跃程度的顺序为：

$$x_1 = x_{13} > x_2 = x_3 = x_5 = x_{14} = x_{15} > x_6 = x_9 = x_8 > x_4 = x_7 = x_{10} = x_{11} = x_{12}$$

4. 3. 3 活跃度综合结论

分别根据以上两个模型得到的活跃度排序（见表 14 和表 15）分别为：

表 14 方法一得到的活跃度排序

活跃度排名	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
论坛用户	经济门外溜达	三公子	XIAOZ	枫	之语嘛	青山客	犀利哥	两元鱼	老猫	来无影去无踪	沙漏	Ear On head	稀奇	诺言	Zerammann

表 14

表 15 方法二得到的活跃度排序

活跃度排名	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
论坛用户	经济门外溜达	三公子	X I A O Z	青山客	老猫	枫	之语嘛	两元鱼	犀利哥	来无影去无踪	沙漏	Ea r On he ad	稀奇	诺言	Ze ra ma nn

表 15

两个表格在排名上略有差别，大致反映了活跃度的几个强度：


活跃度很强：经济门外溜达、三公子、xiaoz；活跃度较强：

枫、之语嘛、青山客、犀利哥、老猫、两元鱼；活跃度一般：

来无影去无踪、沙漏、ear on head；活跃度较差：稀奇、诺言、Zera mann；

4.4 论坛关系圈的识别：

4.4.1 步骤流程图



4.4.2

步骤 1：先确定论坛中其中一个模块的版主，然后再确定版主下面的几个用户，找到其所有发的帖子；例如先确定 <http://www.pinggu.org/bbs/> 站务综合管理区的页面，现要找出用户名为“经济门外溜达”和“xiaoz”的关系圈，在该页面首页能看到有三篇该用户所发的帖子。

步骤 2：运用网络神采数据采集软件对这两个用户所发的每篇帖子的跟帖用户进行

数据信息的提取;

步骤 3: 运用相关软件将统计步骤 2 中确定的跟帖用户在一篇帖子中出现的次数, 并统计出现在多篇帖子中的用户; 上例中经过数据初步筛选如表 16 所示用户 1:

表 16 数据的筛选

用户名 \ 帖号	帖子 1	帖子 2	帖子 3
叉尔施·稀奇	3	2	0
诺言	2	3	1
三公子	1	1	2
zeromann	1	2	1
Sanjianke	2	0	2

表 16

所以得到用户“经济门外溜达”的关系圈为“诺言”、“三公子”、“zeromann”。

上例中经过数据初步筛选如表 17 所示用户 1 用户 2

用户名 \ 帖号	帖子 1	帖子 2	帖子 3
老猫	3	2	1
诺言	2	1	1
ear on head	0	0	2
两元鱼	1	2	1
青山客	2	0	2

表 17

所以得到用户“xiaoz”的关系圈为“老猫”、“诺言”、“两元鱼”。而“诺言”这个用户既属于“经济门外溜达”的关系圈, 又属于“xiaoz”的关系圈。

4.4.3 因为关系圈的确定非常的复杂, 涉及的因素比较多, 下面我们另外用另外一个方法确定某

个用户的关系圈。

步骤 1:

先运用话题用户的识别方法, 对论坛中的某一话题模块得到 M 位话题用户。


步骤 2:

在某话题模块中的话题用户进行活跃用户的识别, 根据隶属度 μ 的大小进行排序。

步骤 3:

剔除活跃度低于平均数的用户, 筛选后得到的用户即可划为该话题的关系圈。

流程图:



5、模型的评价

6.1 模型的优点:

1. 本文在数据的采集过程中运用了网络神采软件,通过这个软件我们可以获取大量的数据,准确而效率高。
2. 通过层次分析以及模糊矩阵中的聚类分析,运用隶属度来分类,方法比较新颖。

6.2 模型的缺点:

1. 本文中出理的数据比较多,因此用网络神采软件来挖掘数据,根据这些数据来验证模型,忽略了个别的用户的特异性。
2. 数据处理时,存在计算机对跟帖内容的主要内容识别不够精确。

6.3 模型的推广: 根据数据的挖掘,提取各种评估指标来建立层次分析模型及模糊决策模型.可推广

运用到例如高质量产品的识别、大气污染水平分析等问题中.

6、参考文献

- 【1】谢季坚等,模糊数学方法及其应用,武汉:华中科技大学出版社,2002.
- 【2】郑美玲 陈兴隆 杨颖,互联网论坛用户的识别与探究,武汉工业与应用数学学会,2010.
- 【3】姜启源,邢文训等.《大学数学实验》.北京:清华大学出版社,2005
- 【4】岂兴明,王占富等.《MATLAB 7.0 程序设计快速入门》.北京:人民邮电出版社,2009
- 【5】白其峥主编.《数学建模案例分析》.北京:海洋出版社,2000
- 【6】李继成主编.《数学实验》.北京:高等教育出版社,2006
- 【7】邹秀芬,陈绍林等.《数值计算方法学习指导书》.武汉:武汉大学出版社,2008
- 【8】韩中庚主编.《数学建模竞赛——获奖论文精选与点评》.北京:科学出版社,2007
- 【9】熊启才主编.《数学模型方法及应用》.重庆:重庆大学出版社,2005. 3
- 【10】王树禾编著.《数学模型基础》.合肥:中国科学技术大学出版社,1996

7、附录

附录 1: 对准则层及方案层判断矩阵进行一致性检验

```
a=[1 1/7 1/3 1/2 1/5;7 1 3 5 3;3 1/3 1 3 1/3;2 1/5 1/3 1 1/5;5 1/3 3 5 1];
[x,y]=eig(a);eigenvalue=diag(y);lamda=eigenvalue(1);
ci1=(lamda-5)/4;cr1=ci1/1.12 %对准则层判断矩阵进行一致性检验
w1=x(:,1)/sum(x(:,1)) %准则层判断矩阵各项权值
b1=[1 1/5 5 1/3 1/2;5 1 9 3 5;1/5 1/9 1 1/7 1/5;3 1/3 7 1 3;2 1/5 5 1/3 1];
[x,y]=eig(b1);eigenvalue=diag(y);lamda=eigenvalue(1);
ci21=(lamda-5)/4;cr21=ci21/1.12 %对方案层判断矩阵 c1 进行一致性检验
w21=x(:,1)/sum(x(:,1)) %方案层判断矩阵 c1 各项权值
```

```

b2=[1 1/7 1/3 1/5 1/3;7 1 5 3 5;3 1/5 1 1/3 1/2;5 1/3 3 1 3;3 1/5 2 1/3 1];
[x,y]=eig(b2);eigenvalue=diag(y);lamda=eigenvalue(1);
ci22=(lamda-5)/4;cr22=ci22/1.12 %对方案层判断矩阵 c2 进行一致性检验
w22=x(:,1)/sum(x(:,1)) %方案层判断矩阵各项 c2 权值
b3=[1 1/5 3 1/3 1/2;5 1 7 3 5;1/3 1/7 1 1/5 1/3 ;3 1/3 5 1 3;2 1/5 3 1/3 1];
[x,y]=eig(b3);eigenvalue=diag(y);lamda=eigenvalue(1);
ci23=(lamda-5)/4;cr23=ci23/1.12 %对方案层判断矩阵 c3 进行一致性检验
w23=x(:,1)/sum(x(:,1)) %方案层判断矩阵 c3 各项权值
b4=[1 1/5 3 1/7 1/3;5 1 7 1/3 3;1/3 1/7 1 1/9 1/5;7 3 9 1 5;3 1/3 5 1/5 1];
[x,y]=eig(b4);eigenvalue=diag(y);lamda=eigenvalue(1);
ci24=(lamda-5)/4;cr24=ci24/1.12 %对方案层判断矩阵 c4 进行一致性检验
w24=x(:,1)/sum(x(:,1)) %方案层判断矩阵 c4 各项权值
b5=[1 3 5 1/3 1/2;1/3 1 3 1/5 1/3;1/5 1/3 1 1/7 1/5;3 5 7 1 3;2 3 5 1/3 1];
[x,y]=eig(b5);eigenvalue=diag(y);lamda=eigenvalue(1);
ci25=(lamda-5)/4;cr24=ci24/1.12 %对方案层判断矩阵 c4 进行一致性检验
w25=x(:,1)/sum(x(:,1)) %方案层判断矩阵 c4 各项权值
w_sum=[w21,w22,w23,w24,w25]*w1 %总排序的权值
ci=[ci21,ci22,ci23,ci24,ci25];
cr=ci*w1/sum(1.12*w1) %对累计总排序进行一致性检验

```

```

a=['关键词']; b=['
主题帖标题'];
n=0;m=length(a)-1;
for j=1:(length(b)-m)
if a==b(j:j+m)
n=n+1;
end
end
n %为标题中出现关键词的次数

```

附录 2: 模糊决策矩阵 $\tilde{D}=(\tilde{r}_{ij})_{m \cdot n}$ 的求解

```

clear;clc;
x=[85 90 100 75 80 85 75 80 85 75 80 85
    85 90 100 60 70 75 75 80 85 60 70 75
    60 70 75 60 70 75 85 90 100 60 70 75
    50 55 60 50 55 60 50 55 60 60 70 75
    50 55 60 60 70 75 75 80 85 60 70 75
    60 70 75 60 70 75 60 70 75 60 70 75
    50 55 60 60 70 75 50 55 60 50 55 60
    60 70 75 60 70 75 50 55 60 50 55 60
    60 70 75 60 70 75 60 70 75 60 70 75
    50 55 60 60 70 75 50 55 60 50 55 60

```

```

50 55 60 60 70 75 50 55 60 50 55 60
50 55 60 60 70 75 50 55 60 50 55 60
60 70 75 85 90 100 85 90 100 85 90 100
85 90 100 75 80 85 60 70 75 60 70 75
50 55 60 60 70 75 85 90 100 75 80 85];           %转化后的三角模糊矩阵
for i=[1,4,7,10]
    c1(:,i)=x(:,i)./max(x(:,i+2));
    c1(:,i+1)=x(:,i+1)./max(x(:,i+1));
    c1(:,i+2)=x(:,i+2)./max(x(:,i));
end;
c1;                                     %对数据进行归一处理
w=[0.25 0.25 0.25];
for m=[1 4 7 10];
    for j=1:15
        y=c1(:,m:m+2);
        r(j,m)=w(1)*y(j,1);
        r(j,m+1)=w(1)*y(j,3)+w(1)*w(2)-w(2)*y(j,3);
        r(j,m+2)=w(1)*y(j,2)+w(3)*y(j,1)-w(3)*y(j,2);
    end
end
r                                     %加权后的模糊决策矩阵
A=r';
for i=1:12;
    M(i,:)=max(A(i,:));
end
M                                     %构造模糊正理想
for i=1:12;
    N(i,:)=min(A(i,:));
end
N                                     %构造模糊负理想
for j=1:15
    for i=1:12
        R1(i,j)=(A(i,j)-M(i))^2;
    end
end

for k=1:15
    B1(k)=sqrt(sum(R1(:,k)));
end
B1;                                     %各对象与正理想之间的距离
for j=1:15
    for i=1:12
        R2(i,j)=(A(i,j)-N(i))^2;
    end
end

```

```

end
for k=1:15
    B2(k)=sqrt(sum(R2(:,k)));
end
B2;          %各对象与负理想之间的距离
for i=1:15
    u(i,1)=B2(i)^2/(B1(i)^2+B2(i)^2);
end
u            %隶属度的求解

```

附录 3： 模糊相似

矩阵 R :

```

R=1    0.6612  0.6026  0.9904  0.2228  0.9207  0.7956  0.9171  0.7841  0.7953  0.7943
      0.8049  0.9626  0.3346  0.5074
0.6612  1    0.9968  0.7468  0.5804  0.9006  0.9805  0.9054  0.984   0.9806  0.981
      0.9774  0.8394  0.4857  0.9781
0.6026  0.9968  1    0.6928  0.6368  0.8641  0.9628  0.8707  0.9676  0.9628  0.9633
      0.9585  0.7952  0.5496  0.9864
0.9904  0.7468  0.6928  1    0.0956  0.9616  0.8617  0.9569  0.8524  0.8617  0.8608
      0.8694  0.9876  0.215   0.6135
0.2228  0.5804  0.6368  0.0956  1    0.1754  0.4098  0.1819  0.4269  0.4105  0.4118
      0.3957  0.0496  0.9898  0.727
0.9207  0.9006  0.8641  0.9616  0.1754  1    0.9679  0.9993  0.9632  0.9679  0.9674
      0.9716  0.992   0.0589  0.8034
0.7956  0.9805  0.9628  0.8617  0.4098  0.9679  1    0.9711  0.9998  1    1    0.9999
      0.9295  0.3046  0.922
0.9171  0.9054  0.8707  0.9569  0.1819  0.9993  0.9711  1    0.9665  0.971   0.9706
      0.9747  0.9905  0.0687  0.8064
0.7841  0.984   0.9676  0.8524  0.4269  0.9632  0.9998  0.9665  1    0.9998  0.9999
      0.9994  0.9225  0.3224  0.9291
0.7953  0.9806  0.9628  0.8617  0.4105  0.9679  1    0.971   0.9998  1    1    0.9999
      0.9294  0.3051  0.9225
0.7943  0.981   0.9633  0.8608  0.4118  0.9674  1    0.9706  0.9999  1    1    0.9998
      0.9288  0.3066  0.9229
0.8049  0.9774  0.9585  0.8694  0.3957  0.9716  0.9999  0.9747  0.9994  0.9999  0.9998
      1    0.9351  0.2898  0.9161
0.9626  0.8394  0.7952  0.9876  0.0496  0.992   0.9295  0.9905  0.9225  0.9294  0.9288
      0.9351  1    0.067   0.7218
0.3346  0.4857  0.5496  0.215   0.9898  0.0589  0.3046  0.0687  0.3224  0.3051  0.3066
      0.2898  0.067   1    0.6386
0.5074  0.9781  0.9864  0.6135  0.727   0.8034  0.922   0.8064  0.9291  0.9225  0.9229
      0.9161  0.7218  0.6386  1

```

R^k 的近似矩阵为 χ :

$\chi=1$	0.7612	0.7026	0.9904	0.8228	0.9207	0.7956	0.9171	0.7841	0.7953	0.7943
	0.8049	0.9626	0.8346	0.9074						
0.7612	1	0.9968	0.7468	0.5804	0.9006	0.9805	0.9054	0.984	0.9806	0.981
	0.9774	0.8394	0.7857	0.9781						
0.6026	0.9968	1	0.6928	0.6368	0.8641	0.9628	0.8707	0.9676	0.9628	0.9633
	0.9585	0.7952	0.5496	0.9864						
0.9904	0.7468	0.6928	1	0.0956	0.9616	0.8617	0.9569	0.8524	0.8617	0.8608
	0.8694	0.9876	0.215	0.6135						
0.2228	0.5804	0.6368	0.0956	1	0.1754	0.4098	0.1819	0.4269	0.4105	0.4118
	0.3957	0.0496	0.9898	0.727						
0.9207	0.9006	0.8641	0.9616	0.1754	1	0.9679	0.9993	0.9632	0.9679	0.9674
	0.9716	0.992	0.0589	0.8034						
0.7956	0.9805	0.9628	0.8617	0.4098	0.9679	1	0.9711	0.9998	1	1
	0.9295	0.3046	0.922							
0.9171	0.9054	0.8707	0.9569	0.1819	0.9993	0.9711	1	0.9665	0.971	0.9706
	0.9747	0.9905	0.0687	0.8064						
0.7841	0.984	0.9676	0.8524	0.4269	0.9632	0.9998	0.9665	1	0.9998	0.9999
	0.9994	0.9225	0.3224	0.9291						
0.7953	0.9806	0.9628	0.8617	0.4105	0.9679	1	0.971	0.9998	1	1
	0.9294	0.3051	0.9225							
0.7943	0.981	0.9633	0.8608	0.4118	0.9674	1	0.9706	0.9999	1	1
	0.9288	0.3066	0.9229							
0.8049	0.9774	0.2585	0.8694	0.3957	0.9716	0.9999	0.9747	0.9994	0.9999	0.9998
	1	0.9351	0.2898	0.9161						
0.9626	0.8394	0.7952	0.9876	0.796	0.992	0.9295	0.9905	0.9225	0.9294	0.9288
	0.9351	1	0.777	0.7218						
0.7346	0.7857	0.7496	0.715	0.9898	0.589	0.5046	0.687	0.5224	0.5051	0.5066
	0.5898	0.67	1	0.6386						
0.5074	0.9781	0.9864	0.6135	0.727	0.8034	0.922	0.8064	0.9291	0.9225	0.9229
	0.9161	0.7218	0.6386	1						

附录 4： 数据的采集：

《网络神采》是一款专业的网络信息采集软件, 通过灵活的规则可以从任何类型的网站采集信息, 如新闻类网站、论坛、电子商务网站、求职招聘网站等. 支持网站登录采集、网站跨层采集、POST 采集、脚本页面采集、动态页面采集等高级采集功能. 本文就是运用《网络神采》对 <http://www.pinggu.org/bbs/> 和 <http://bbs.55bbs.com> 的论坛用户进行数据挖掘.

1、新建任务



任务编辑

常规设置 | 起始地址 | 导航规则 | 采集规则 | 采集结果 | 插件设置

常规

任务名称: 人大经济论坛

备注:

高级

线程数量: 1 | 网址编码: gb2312 | 历史记录容量: 1000

任务日志: ☒ 输出详细日志 ☐ 保存日志到文件

网站登录

☒ 手工登录 ☐ 自动登录

Cookie: | 进行手工登录 | 设置自动登录

定时采集

☒ 每当天 ☐ 每隔 0 天 0 点 0 分

☐ 启用定时采集 ☐ 限制时间范围 设置时间范围 ☐ 任务完成后取消定时采集


[点击打开《源文件查看器》](#)

确定 (D) | 取消 (C) | 应用

2、起始地址设置：采集一个网站时必须有一个入口 [URL](#)，称之为“起始地址”。将列表做为起始地址，然后根据提取内容的 URL 可以按不同分类将多个列表做为采集入口，以新闻为例，可以将国内新闻、科技新闻、军事新闻等多个列表 URL 添加为起始地址。



3、“导航规则”规定了如何从“[起始地址](#)”走到最终采集页面.，“导航规则”规定了如何从“列表”提取“内容”的网址,并访问“内容”页面以采集所需信息. “内容”网址是根据“导航规则”的“[下一层网址模板](#)”从“列表”[网页源文件](#)中来提取.



4、采集规则，“采集规则”决定了如何从网页源文件提取所需信息。“采集规则”通过前后标志来定位需要采集的内容，每一种内容都对应一条“采集规则”。一定要注意“采集规则”的前后顺序，必须以源文件中的内容顺序为准。另外，第一条规则的“前标志”，在没有[限定内容采集范围](#)的情况下，必须能够从[网页源文件](#)开始处被定位到。保存设置并确定。

任务编辑

☐ 常规设置
 ☐ 起始地址
 ☐ 导航规则
 ☒ 采集规则
 ☐ 采集结果
 ☐ 插件设置

采集规则列表

序号	规则名称	所属层次	数据列名	不能重复	信息前标志	信息后标志
1	用户名	最终页面	用户名	False	<p>昵称: 	</p>
2	帖子数	最终页面	帖子数	False	<dl class="profile s...	 </dd>
3	精华	最终页面	精华	False	<dt>精华</dt><dd>	 </dd>
4	经验	最终页面	经验	False	</dd><dt>经验</dt><dd>	 </dd>
5	威望	最终页面	威望	False	<dt>威望</dt><dd><fo...	
6	学术水平	最终页面	学术水平	False	dt>学术水平</dt><dd>	 </dd>
7	热心指数	最终页面	热心指数	False	<dt>热心指数</dt><dd>	 </dd>
8	信用等级	最终页面	信用等级	False	<dt>信用等级</dt><dd>	 </dd>

规则名称: 所属层次:

数据库字段: ☐ 发布时该字段的数据不能重复

信息前标志: 信息后标志:

☐ 高级选项
 ☐ 下载目录设置
 ☐ 保留HTML标记
 ☐ 特殊结果设置
 ☐ 采集结果替换
 ☐ 合并分页内容

☐ 全局规则
 ☐ 静态规则
 ☐ 关键规则
 ☐ 使用插件采集数据

☐ 下载内容图片
 ☐ 下载内容Flash
 ☐ 下载内容附件
 附件URL标志:

☐ 下载独立文件
 ☐ 探测真实地址

新建(N) 保存(S) 删除(D) 上移(U) 下移(D) 清空(C) 导入(I) 导出(O)

[点击打开《源文件查看器》](#)

4 数据采集：回到主页面，点击开始选项软件开始执行挖掘信息操作。

The screenshot displays the Pingguo software interface. On the left is a file explorer pane with a tree view showing '根文件夹' (Root Folder) and '其它示例' (Other Examples). The main window is divided into several sections:

- Task List:** A table with columns for task name, completion status, and various metrics.

任务名称	完成提取	提取网址	完成起始	起始地址	历史记录	当前采集	采集结果	发布
百度新闻搜索								
郑州大学新闻信息								
人大经济论坛	135	153	1	1	0	36	75	
人大经济2	200	251	1	1	0	0	0	
- User Post Table:** A detailed table showing user information and post statistics.

用户名	帖子数	精华	经验	威望	学术水平	热
精灵	193	0	559 点	0	0 点	
两元鱼	726	0	2542 点	0	32 点	
青山客	5149	2	4961 点	4	54 点	
zeromann	45	1	1314 点	0	25 点	
来无影去无踪...	601	0	1158 点	0	30 点	
小龙	91	0	364 点	0	0 点	
11			1886 点	0	1 点	11
- Task Details:** A section at the bottom showing the current task's URL and status.

请求: <http://www.pingguo.org/bbs/forum-168-1.html>
 采集内容: 内容采集失败!
 请求: <http://www.pingguo.org/bbs/forum-165-1.html>

The status bar at the bottom indicates '1 个任务' (1 task) and '运行中' (Running).