

摘要

风电场的发电功率预测是保证电网功率平衡和运行安全的重要环节,本文对风电场发电功率建立预测模型。

对问题一,通过对灰色预测、ARIMA 以及遗传神经网络预测模型引入预测误差反馈控制,使得预测模型具有自适应调节预测精度的能力,大大提高了三种模型的预测精度,得到了给定日期的发电功率预测值,最终确立了遗传神经网络预测模型为较高精度模型。

对问题二,在三个模型得到的预测结果和误差基础上,比较了单台风电机组功率以及多机总功率预测的相对误差,得到了预测误差存在的普遍规律:预测误差随着预测数据使用量的增多而最终呈增大趋势,并且机组汇聚会减小预测误差。

对问题三,利用动态神经网络的特性,提出对时间序列进行预测的动态神经网络模型,并用于风电功率的预测中,提高了预测精度和稳定性。结果表明动态神经网络在风电功率的有效性和实用性。最后分析论证了阻碍风电功率实时预测精度进一步改善的主要因素。

关键词: 风电 灰色预测 ARIMA 遗传神经网络 动态神经网络

一、问题的提出

1.1 问题的背景

随着全球气候问题以及能源危机的出现，人类对可再生能源的依赖越显突出。风能是一种可再生、清洁的能源，风力发电是最具大规模开发技术经济条件的非水电再生能源。现今风力发电主要利用的是近地风能。

近地风具有波动性、间歇性、低能量密度等特点，因而风电功率也是波动的。大规模风电场接入电网运行时，大幅度地风电功率波动会对电网的功率平衡和频率调节带来不利影响。

风能作为一种可再生洁净能源的代表，有着广泛的发展前景。随着大规模风电场的兴起，风能越来越多地被应用到发电行业。由此也给电力系统带来一系列问题，例如电压问题、电能质量、调度方案等，特别是风电场输出功率的不可预知性，给电网运行带来极大的困难。对风电场输出功率进行预测不但能提高电网运行水平，保证电网的功率平衡和运行安全。而且可以降低非可再生能源的消耗，提高电力系统经济性，减少温室气体排放，意义重大。

1.2 问题的提出

结合对题目的理解及附件中各机组的数据，试建立数学模型，解决以下问题

(1) 结合附件中各机组的数据对风电功率进行实时预测及误差分析，并检验预测结果是否满足相关预测精度的相关要求。具体要求：

- 采用不少于三种预测方法（至少选择一种时间序列分析类的预测方法）；
- 预测量：
 - a. PA, PB, PC, PD; b. P4; c. P58。
- 预测时间范围分别为（预测用的历史数据范围可自行选定）：
 - a. 5月31日0时0分至5月31日23时45分；
 - b. 5月31日0时0分至6月6日23时45分。
- 试根据题目给出关于实时预测的考核要求分析你所采用方法的准确性；
- 你推荐哪种方法？

(2) 根据问题一的预测结果分析风电机组的汇聚对于预测结果误差的影响。并根据单台风电机组功率与多机总功率预测的相对误差，判断其带有怎样的普遍性规律。从中对风电机组汇聚给风电功率预测误差带来的影响做出预期效果。

(3) 在问题1的基础上，构建有更高预测精度的实时预测方法（方法类型不限），并用预测结果说明其有效性。

并通过求解上述问题，请分析论证阻碍风电功率实时预测精度进一步改善的主要因素。判断风电功率预测精度是否能无限提高。

二、问题的分析

2.1 问题一

选取灰色预测模型、ARIMA 模型、遗传神经网络模型作为预测模型，并在此基础上，加入了预测精度的误差反馈控制。预测过程中是用预测得到的数据再去预测新的数据，随着使用预测数据量的增加，预测值的误差会越来越偏离实际值，而加入误差反馈控制可以很好地将预测误差控制在某一给定范围之内。

2.2 问题二

在问题一的基础上，对预测结果的分析及对比，选取最优模型。并根据单台风电机功率与多机总功率预测的相对误差，判断其带有的普遍性规律，从而提出建议。

2.3 问题三

传统的时间序列分析方法，如 ARMA 模型等，都要求时间序列具有正态分布，全局平稳等缺点。神经网络的预测法具有自适应、自学习等缺点，能较好地处理不确定、非线性的预测问题。而一般的神经网络如 BP，RBF 只能处理静态对象，故本文提出基于动态神经网络的时间序列预测模型。

三、问题假设与符号说明

3.1 问题假设

- 假设风电功率与其它影响因素无关，只考虑风电功率在各时间段上的变化
- 假设风电机组工作不受人为因素干扰
- 假设实时监测数据准确

3.2 符号说明

四、模型的建立与求解

4.1 问题一

4.1.1 问题的思路




图 4-1 思路流程图

此图最主要的特点是在传统预测模型的基础之上，加入了预测精度的误差反馈控制，这样的优点在于能够使得传统的预测模型通过误差的反馈自适应地调节预测精度，大大提高了原来预测模型的精度，之所以这样做的原因在于，预测过程中是用预测得到的数据再去预测新的数据，随着使用预测数据量的增加，预测值的误差会越来越偏离实际值，而加入误差反馈控制可以很好地将预测误差控制在某一给定范围之内。

4.1.2 模型一的建立(灰色预测)

基于上述思想建立灰色预测模型

1) 对已知数据列做必要的检验处理. 设参考数据为:

$$x(0) = (x(0)(1), x(0)(2), \dots, x(0)(n)) \quad (1)$$

计算数列的级比：

$$\lambda(k) = \frac{x^{(0)}(k-1)}{x^{(0)}(0)} \quad (k=2,3,\dots,n) \quad (2)$$

如果所有的级比 $\lambda(k)$ 都落在可容覆盖 $X = (e^{-\frac{2}{n+1}}, e^{\frac{2}{n+1}})$ 内，则数列 $x^{(0)}$ 可以作为模型 GM(1,1) 的预测数据。

否则取适当的常数 c 做变换： $y^{(0)}(k) = x^{(0)}(k) + c \quad (k=1,3,\dots,n)$ 使得数列 $y^{(0)} = (y^{(0)}(1), y^{(0)}(2), \dots, y^{(0)}(n))$ 的级比：

$$\lambda_y(k) = \frac{y^{(0)}(k-1)}{y^{(0)}(k)} \in X \quad (k=2,3,\dots,n) \quad (3)$$

2) 建立模型 GM (1, 1)

所采用的 GM(1,1) 模型的灰色微分方程为：

$$x^{(0)}(k) + az^{(1)}(k) = b \quad (4)$$

其时间响应序列为：

$$\hat{x}^{(1)}(k+1) = \left(x^{(1)}(0) - \frac{b}{a} \right) e^{-ak} + \frac{b}{a} \quad k=1,2,\dots,n \quad (5)$$

参数 a, b 根据 $u = [a, b]^T = (B^T B)^{-1} B^T Y$ 求解，其中：

$$B = \begin{bmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \dots & \dots \\ -z^{(1)}(n) & 1 \end{bmatrix}, \quad Y = \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \dots \\ x^{(0)}(n) \end{bmatrix},$$

$$z^{(1)}(k) = 0.5x^{(1)}(k) + 0.5x^{(1)}(k-1) \quad (6)$$

最终解得微分方程预测模型为：

$$\hat{x}^{(0)}(k+1) = \hat{x}^{(1)}(k+1) - \hat{x}^{(1)}(k); \quad k=1,2,\dots,n \quad (7)$$

4.1.3 模型一的求解与结果分析

根据以上思想及模型求解原理，MATLAB 编程（程序见附录一），预测各机组在 2006-5-31 的风电功率。以下是 2006-5-31 各机组的部分预测数据，完全数据

请见附件。

表 4-1 2006-5-31 各机组预测数据

	PA	PB	PC	PD	P4	P58
1	249.0938	224.5313	141.1875	160.5938	775.4064	11634.84
2	446.501	426.1212	481.2834	355.1863	1703.233	21879.79
3	418.6028	416.5484	461.046	341.2238	1634.053	21000.99
4	392.4477	407.1907	441.6595	327.8102	1567.682	20157.49
5	367.9268	398.0433	423.0881	314.9239	1504.008	19347.87
6	344.938	389.1013	405.2977	302.5442	1442.919	18570.77
7	323.3856	380.3602	388.2554	290.6511	1384.312	17824.88
8	303.1799	371.8155	371.9297	279.2255	1328.086	17108.95
9	284.2366	363.4627	356.2904	268.2491	1274.143	16421.77
10	266.477	355.2976	341.3088	257.7041	1222.391	15762.19
11	249.827	347.3159	326.9571	247.5737	1172.741	15129.11
12	234.2173	339.5135	313.2089	237.8415	1125.108	14521.45
13	219.5829	331.8863	300.0388	228.4919	1079.409	13938.2
14	205.863	324.4306	287.4225	219.5098	1035.567	13378.38
15	193.0003	317.1423	275.3367	210.8808	993.5054	12841.04
16	180.9412	310.0177	263.759	202.5911	953.1521	12325.28

灰色预测关于 A 机组预测值与真实值的比较图 4-2，其它机组的见附录二




图 4-2 A 机组预测值与真实值的比较

从上图中可以明显看出系统预测误差的自适应调节过程，这样的调节过程有机地将模型自动分为几个灰色预测段，使得每段的预测精度都大大提高，从而使得整个预测精度大大提高。将数据代入准确率计算公式

$$r_1 = \left(1 - \sqrt{\frac{1}{N} \sum_{k=1}^N \left(\frac{P_{Mk} - P_{Pk}}{Cap} \right)^2} \right) \times 100\% \quad (8)$$

计算得到 $r_{1PA} = 96.94\%$ ，其他机组的准确率计算结果汇总见表 4-2。

表 4-2 各机组预测曲线准确率

	PB	PC	PD	P4	P58
准确率	96.61%	96.48%	96.92%	97.25%	97.74%

从表 4-2 中可以看出汇聚后的风电机组曲线的准确率比单个机组要高。

4.1.4 模型二的建立 (ARIMA 模型)

时间序列建模基本步骤

对于随机时间序列，可先判断时间序列的平稳性，若平稳则可直接建立 *ARMA* 模型；若不平稳则通过差分将非平稳时间序列平稳化，然后再建立 *ARMA* 模型。这样可以将这四种时间序列的建模过程统称为 *ARIMA* 建模过程。

ARIMA 建模的流程可分为序列平稳性检验、模型识别、参数估计、模型检验和建立预测模型五步，建模预测流程如图 4-3：




图 4-3 *ARIMA* 建模预测流程

在这个建模过程中，每一步主要的任务分别是：

1) 平稳性检验及其平稳化

对时间序列进行平稳性检验，常用的检验方法是扩展的 Dickey-fuller (简 ADF 检验)。ADF 检验法需要进行如下回归：

$$\nabla Y_t = \beta_0 + \lambda T + (\rho - 1)Y_{t-1} + \sum_{i=1}^p \gamma_i Y_{t-i} + \varepsilon_t \quad (9)$$

式中 β_0 为截距项, T 为趋势项, ∇ 为一阶差分, ε_t 为随机误差项, 滞后项 p

可按照赤池准则 (ACI) 来确定。对于 ADF 检验而言,

原假设为 $H_0: p=1$;

备择假设为 $H_1: p<1$ 。

若 ADF 值大于临界值, 则接受 H_0 , 意味着变量时间序列 Y_t 含有一个单位根,

即该时间序列不是平稳的; 反之, 若 ADF 小于临界值, 则拒绝 H_0 , 接受 H_1 ,

表明该时间序列是平稳的。对一个非平稳的时间序列 $\{Y_t\}$, 对其进行一阶差分公式为:

$$\nabla Y_t = Y_t - Y_{t-1} = (1-B)Y_t \quad (10)$$

因此, 一个 d 阶差分后的时间序列就可以写为:

$$\nabla^d Y_t = (1-B)^d Y_t \quad (11)$$

式中, B 为滞后算子, $\nabla = 1-B$ 为引入的有序差分算子, d 为差分阶数。对于不平稳的风速序列, 一般可经过适当次数差分将非平稳的数据序列转化为均值为零的平稳随机序列。

2) 模型识别

模型识别包括模型的类型选择和模型定阶, 对平稳的时间序列数据, 可借助序列的自相关函数 AC 和偏相关函数 PAC 来识别模型:

$$AC: \rho_k = \frac{\sum_{i=1}^{n-k} Y_i \cdot Y_{i+k}}{\sum_{i=1}^n Y_i^2}, k=1, 2, \dots \quad (12)$$

$$PAC: \phi_{kk} = \begin{cases} \rho_1, & k=1 \\ \frac{\rho_k - \sum_{j=1}^{k-1} \phi_{k-1j} \cdot \rho_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1j} \cdot \rho_{k-j}}, & k=2, 3, \dots \end{cases} \quad (13)$$

于是, 通过其自相关函数和偏相关函数的计算就可判断模型的类型, 列表 4-3 如下:

表 4-3 AR、MA 和 ARMA 模型的判断

类别	模型名称		
	AR	MA	ARMA
自相关函数	拖尾	截尾	拖尾
偏相关函数	截尾	拖尾	拖尾

模型类型确定后，还需知道模型的阶数，前面提到的自相关函数和偏相关函数截尾性判别就是其中的一种简单定阶法；此外，常用的是最佳准则函数定阶法，如用赤池信息 (*AIC*) 准则、施瓦茨 (*SC*) 准则等。*AIC* 和 *SC* 准则的一般形式分别为：

$$AIC(p, q) = -\frac{2 \ln L}{n} + \frac{2(p+q)}{n} \quad (14)$$

$$SC(p, q) = -\frac{2 \ln L}{n} + \frac{2(p+q) \ln(n)}{n} \quad (15)$$

式中， $\ln L$ 是模型的对数似然函数值， n 为观测值数目， p 、 q 分别为 *AR* 和 *MA* 的阶数。*AIC* 准则和 *SC* 准则的取值都是越小越好。

此外，可决系数是判断回归模型拟合程度优劣的数量指标，其表示如下：

$$R^2 = \frac{\sum (\hat{Y}_t - \bar{Y})^2}{\sum (Y - \bar{Y})^2} \quad (16)$$

式中的取值范围是 $[0, 1]$ ， R^2 值越大模型的拟合程度越高。

3) 模型参数估计

经过模型识别后，模型的类别和阶数都已经初步确定，下一步就需要估计模型中的未知参数。可采用最小二乘法来估计模型中的参数，其目标是使得式 (17) 残差的平方和达到最小值。

$$\sum_{t=1}^n \varepsilon_t^2 = \sum_{t=1}^n (\theta_q^{-1}(B) \phi_p(B) \nabla^d Y_t)^2 \quad (17)$$

4) 模型检验

经过模型识别和参数估计后，最后还要检验确定模型是否恰当，如果检验通过，说明模型符合要求，就可以进行预测工作了；反之，那么就需要修改模型或重新识别模型，直至满足要求。

由于前面随机时间序列模型的识别与估计是在假设随机扰动项是一白噪声的基础上进行的，因此，对于建立的模型，就需要检验其残差序列：

$\hat{\varepsilon}_t = Y_t - \hat{Y}_t$ ($\hat{Y}_t$ 为预测值) 是否为白噪声的一个样本序列。

判定残差序列是不是白噪声序列的方法很多，在实际检验中最常用的是自相关函数检验法，即检验残差序列是否存在自相关性。

4.1.5 模型二的求解与结果分析

本题中要求对给定数据进行风电功率实时预测并检验预测结果是否满足预测精度的相关要求。选取风电场的发电功率值作为分析使用的样本数据源，数据源的序列为每 15 分钟采样一个点，将其中 5 月 29 日 0 时 0 分至 5 月 30 日 23 时 45 分的共 192 个风电功率值作为建模用。然后用所建模型对 5 月 31 日 0 时 0 分至 5 月 31 日 23 时 45 分的 96 个风电功率值做提前一天的预测，之后再与 5 月 31 日的实际值进行对比，分析预测的误差。在具体的预测过程中，不考虑机器故障、认为操作等因素对风速的影响，纯粹根据历

史风电功率数据进行预测工作，算例分析中所采用的建模分析软件是 Eviewss6.0。

1) 数据的分析及处理

由前文可知，对随机时间序列建模前需对风电功率序列的平稳性进行平稳性检验，因此，首先计算序列的自相关函数和偏相关函数。图 4-2 为风速时间序列 $\{Y_t\}$ ，图 4-3 为 $\{Y_t\}$ 的相关函数计算结果，其中 AC 表示自相关函数，PAC 表示偏相关函数。




图4-4 风电功率时间序列 $\{Y_t\}$




图 4-5 序列 $\{Y_t\}$ 的相关图

由图 4-5 可以看出，自相关系数不能很快的落入随机区内(即趋于 0)，因此该时间序列是非平稳的。通过差分的方式，将非平稳的时间序列其转化为平稳的时间序列。图 4-6 为对原序列进行一阶差分后得到的序列 $\{Y_t'\}$ ，其对应的相关函数计算结果见图 4-7。




图 4-6 一阶差分后风电功率的序列 $\{Y'_t\}$




图 4-7 序列 $\{Y'_t\}$ 的相关图

由图 4-7 可以看出，序列的自相关系数能较快的落入到随机区域内，由此初步判断该序列是平稳的。为了增加判断的可靠性，对一阶差分序列作 ADF 检验，其结果见表 4-4。

表4-4 一阶差分序列 ADF 检验结果

	t-Statistic	Prob. *
Augmented Dickey-Fuller test statistic	-12.36177	0.0000
Test critical values: 1% level	-3.465202	
5% level	-2.876759	
10% level	-2.574962	

由表 4-4 可以看出 ADF 的检验统计量等于-12.36177，小于 $\alpha=1\%$ ，5%和10%的临界值，说明在 95%置信水平下完全有理由拒绝原假设，即一阶差分后的风速数据序列是平稳的。

2) 模型的建立

对时间序列进行以上平稳处理后，即可在平稳差分序列的基础上进行时间序列的建模。由图 4-3 可知，该序列的自相关函数是拖尾的，而偏相关函数也有一定的拖尾特点，故 $\{Y_t\}$ 适合建立 ARMA(p,q) 模型。ARMA 模型的精确定阶比较困难，我们可借助 Eview6.0 软件，实现对模型的定阶。使用软

件工具可避免繁杂的数据计算，由软件计算出不同 (p,q) 组合 (要求 $0 \leq p \leq \sqrt{n}, 0 \leq q \leq \sqrt{n}$) 的 *SC*、*AIC* 值和可决系数 R^2 值，通常采用由低到高的试探法进行，选择能使得 *SC* 或 *AIC* 值最小及调整对值较大的阶数，将其定为模型的阶数。ARMA 模型主要阶数的参数比较如表 4-5。

表 4-5 ARMA 模型的参数值比较			
模型	<i>AIC</i> 值	<i>SC</i> 值	调整 R 值
ARMA(1,1)	12. 5288	12. 5570	0. 1833
ARMA(1,2)	12. 5009	12. 5521	0. 2094
ARMA(2,1)	12. 5334	12. 5846	0. 1833
ARMA(2,2)	12. 5101	12. 5788	0. 2144
ARMA(3,1)	12. 5076	12. 5764	0. 2186
ARMA(3,2)	12. 5157	12. 6018	0. 2205
ARMA(3,3)	12. 5247	12. 6280	0. 2218
ARMA(3,4)	12. 5310	12. 6515	0. 2251
ARMA(4,5)	12. 4979	12. 6535	0. 2704
ARMA(5,6)	12. 4579	12. 6487	0. 3106

根据模型的定阶准则，通过综合比较 *SC* 值、*AIC* 值及调整扩值，发现 ARMA(1,2) 是相对较好的模型，故选择 ARMA(1,2) 模型作为该风速数据的时间序列模型。随后由 Eview6. 0 软件对模型 ARMA(1,2) 进行参数估计和检验的结果如表 4-3。

表 4-6 ARMA(1,2) 模型参数估计及检验结果

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	0. 852033	0. 071700	11. 88324	0. 0000
MA(1)	-1. 383176	0. 107832	-12. 82713	0. 0000
MA(2)	0. 402262	0. 097621	4. 120643	0. 0001
R-squared	0. 209382	Mean dependent var	-1. 692432	

Adjusted R-squared	0.200926	S.D. dependent var	139.1860
S.E. of regression	124.4196	Akaike info criterion	12.50086
Sum squared resid	2894804.	Schwarz criterion	12.55213
Log likelihood	-1184.582	Hannan-Quinn criter.	12.52163
Durbin-Watson stat	1.933145		

由于 t 检验的相伴概率值均小于 0.05, 表明在 95% 的置信区间内各项系数值均可接受。故 ARMA(1,2) 模型方程为:

$$Y_t' = 0.8520Y_{t-1}' + \varepsilon_t' - 1.3832\varepsilon_{t-1}' + \varepsilon_{t-2}' \quad (18)$$

3) 模型的检验和预测

对 ARMA(1,2) 模型的合适性进行检验, 即对模型残差序列 ε_t 进行白噪声检验。




图 4-8 参差检验图

利用 “Static” 方法来估计 5 月 31 日 0 时 0 分至 5 月 31 日 23 时 45 分的 Y_t' , 我们可以得到如图 4-9 所示的结果。从图中可以看到, “Static” 方法得到的预测值波动性要大; 同时, 方差比例的下降也表明较好的模拟了实际序列的波动, Theil 不相等系数为 0.60, 其中协方差比例为 0.65, 表明模型的预测结果较理想。




图 4-9 Static 预测方式结果

由图 4-8 可以看出残差序列的样本自相关系数基本都落入随机区间，近似都等于零，表明残差序列是纯随机的，模型通过检验。因此，最后采用 ARMA(1,1,2) 模型用于风电功率的预测，代入 $Y_t' = 0.8520Y_{t-1}' + \varepsilon_t' - 1.3832\varepsilon_{t-1}' + \varepsilon_{t-2}'$ 后经反差分，即可得到对应时刻的风速预测值 $\hat{Y}_t$ 。通过准确率公式，算出 $P_A = 98.59\%$ ，运用递归方法，便可得到 5 月 31 日逐时的风速预测值。预测 P_A 的结果和误差见表 4-7。

表 4-7 预测 P_A 的结果和误差

时序	实际值	预测值	相对误差	时序	实际值	预测值	相对误差
0	249.094	229.236	7.97%	11	410.625	353.354	13.95%
1	355.313	275.873	22.36%	12	106.969	125.164	17.01%
2	362.813	365.624	0.77%	13	68.813	90.335	31.28%
3	323.813	292.514	9.67%	14	13.313	8.2070	38.35%
4	338.625	278.541	17.74%	15	56.531	52.348	7.40%
5	411.938	343.098	16.71%	16	55.219	18.715	66.11%
6	364.688	372.020	2.01%	17	95.531	40.013	58.11%
7	405.375	456.203	12.54%	18	74.156	56.652	23.60%
8	496.219	535.689	7.95%	19	54.469	87.007	59.74%
9	375.656	446.546	18.87%	20	388.875	317.869	18.26%
10	380.813	399.148	4.81%	21	264.656	264.821	0.06%

运用模型一同样的方法可以算出 P_B 、 P_C 、 P_D 、 P_4 、 P_{58} 以及 5 月 31 日 0 时 0 分至 6 月 6 日 23 时 45 分的结果和误差，这里给出 P_B 、 P_C 、 P_D 、 P_4 、 P_{58} 的准确率如表 4-8。

表 4-8 5 月 31 日各机组预测曲线准确率

	P_B	P_C	P_D	P_4	P_{58}
准确率	98.34%	98.13%	98.41%	89.90%	99.92%

同样从表 4-8 中可以看出汇聚后的风电机组曲线的准确率比单个机组要高。

4.1.6 模型三的建立（遗传神经网络模型）

在目前所应用的各种神经网络模型中，应用最为广泛的是 BP 网它具有结构简单、状态稳定优点。但在 BP 网的应用过程中也面临着网络训练时间长、容易陷入局部极小值、隐层节点数不易确定等缺点。为了有效地克服 BP 网的困难，我们将遗传算法与 BP 网络有机地融合，使他们之间相互补充，增强各自的能力。

遗传算法优化 BP 神经网络是用遗传算法来优化 BP 神经网络的初始权值和阈值，使优化后的 BP 神经网络能够更好的预测函数输出。遗传算法优化 BP 神经网络的要素包括种群初始化、适应度函数、选择操作、交叉操作和变异操作。

1) 种群初始化

个体编码方法为实数编码，每个个体均为一个实数串，由输入层与隐含层连接权值、隐含层阈值、隐含层与输出层连接权值以及输出层阈值 4 部分组成。个体包含了神经网络全部权值和阈值，在网络结构已知的情况下，就可以构成一个结构、权值、阈值确定的神经网络。

2) 适应度函数

根据个体得到 BP 神经网络的初始值和阈值，用训练数据训练 BP 神经网络后预测系统输出，把预测输出和期望输出之间的误差绝对值和 E 作为个体适应度值 F ，计算公式为

$$F = k(\sum |y_i - o_i|) \quad (19)$$

3) 选择操作

遗传算法选择操作有轮盘赌法、锦标赛法等多种方法，本案例选择轮盘赌法，即基于适应度比例的选择策略，每个个体 i 的选择概率 P_i 为

$$f_i = k / F_i \quad (20)$$

$$P_i = \frac{f_i}{\sum_{j=1}^N f_j} \quad (21)$$

式中， F_i 为个体 i 的适应度值，由于适应度值越小越好，所以在个体选择前对适应度值求倒数； k 为系数； K 为种群个体数目。

4) 交叉操作

由于个体采用实数编码，所以交叉操作方法采用实数交叉法，第 K 个染色体 a_k 和第 l 个染色体 a_l 在 j 为的交叉操作方法如下：

$$\begin{cases} a_{kj} = a_{kj}(1-b) + a_{ij}b \\ a_{ij} = a_{ij}(1-b) + a_{kj}b \end{cases} \quad (22)$$

式中, b 是 $[0, 1]$ 间的随机数。

5) 变异操作

选取第 i 个个体的第 j 个基因 a_{ij} 进行变异, 变异操作方法如下:

$$a_{ij} = \begin{cases} a_{ij} + (a_{ij} - a_{\max}) \cdot f(g) \rightarrow r > 0.5 \\ a_{ij} + (a_{\min} - a_{ij}) \cdot f(g) \rightarrow r \leq 0.5 \end{cases} \quad (23)$$

式中, $a_{\max}$ 为基因 a_{ij} 的上界; $a_{\min}$ 为基因 a_{ij} 的下界 $f(g) = r_2(1 - g/G_{\max})^2$; r_2 为一个随机数; g 为当前迭代次数; $G_{\max}$ 是最大进化次数; r 为 $[0, 1]$ 间的随机数。

遗传神经网络的算法实现流程如图 4-10 所示。





图 4-10 遗传神经网络算法流程

4.1.7 模型三的求解与结果分析

在本问题中, 由于实时预测要预测后面 16 个时刻的风电功率, 为了方便动态自适应调节, 我们采用的 BP 网络输入层数为 16 层, 隐含层为 10 层, 输出层为 1 层。具体实现为, 取 32 个历史数据 $[x(1), x(32)]$, 网络模型如下:



也就是用 $[x(i), x(i+16)]$ 预测 $x(i+17)$ ，然后用 $[x(i+1), x(i+17)]$ 构造的新的16个数据预测 $x(i+18)$ ，依此类推。遗传的种群规模为50，遗传代数100。文中仅用附件一中PA的数据作为举例说明，其他数据预测结果见附录。取PA中前32个数据作为模型的应用说明，在MATLAB中编程(程序见附录三)得到网络训练图、网络测试图和模型预测结果如图4-11和图4-12所示(其他结果类似，文中不再加以重复说明，以下是2006-5-31的相关数据)。




图 4-11 遗传神经网络训练、网络测试图




图 4-12 模型预测结果

从图中可以看出,预测数据中不乏含有某些个别波动很大的值,但预测的大体都是波动很小的,并且出现大幅度波动的条件都是之前很大一部分预测值满足预测要求,随着预测数据的使用增多,预测误差越来越大,随即出现大波动,然后误差又重新减小,继而又增大,如此循环,这正是我们设计控制误差要求的完美体现,即预测误差随着预测数据使用量的增加而增加,当增加到极限范围时,系统变自动更新为实时测得的数据,又重新开始下一轮的预测,如此循环,能够很好地控制预测的精度。下表给出了 2006-5-31 当日 PA 的部分预测数据, PB、PC、PD、P4 以及 P58 的预测值(见附录四)。

表 4-9 2006-5-31 当日 96 个时刻的预测值

	实际值	预测值	误差
1	249.0938	231.7951	17.29866
2	355.3125	415.0039	-59.6914
3	362.8125	470.3778	-107.565
4	323.8125	306.4045	17.40799
5	338.625	273.6791	64.94592
6	411.9375	412.0338	-0.09634
7	364.6875	325.8772	38.81027
8	405.375	302.6919	102.6831
9	496.2188	516.1319	-19.9131
10	375.6563	354.4917	21.16456
11	380.8125	271.3816	109.4309
12	410.625	489.1299	-78.5049
13	106.9688	138.4586	-31.4898
14	12	4.502876	7.497124
15	-3.5625	5.338757	-8.90126
16	10.78125	10.58962	0.191627

根据附件一所给准确度计算公式,

$$r_1 = \left(1 - \sqrt{\frac{1}{N} \sum_{k=1}^N \left(\frac{P_{Mk} - P_{Pk}}{Cap} \right)^2} \right) \times 100\% \quad (24)$$

代入数据可以计算得到,上述预测模型的准确度 $r_{1PA} = 97.59\%$ 。其他数据见附录。

下表是各机组的预测曲线准确率汇总。

表 4-10 各机组预测曲线准确率

	PB	PC	PD	P4	P58
准确率	97.95%	98.37%	98.33%	98.44%	98.59%

同样地,运用上述遗传神经网络模型,我们可以预测各机组在 2006-5-31 至 2006-6-6 期间的风电功率。以下是 2006-5-31 至 2006-6-6 期间, PA 的部分预测数据,完全数据请见附录。

表 4-11 P_A 2006-5-31 至 6-6 部分预测数据

	5-31	6-1	6-2	6-3	6-4	6-5	6-6
1	396.0809	268.4878	348.4763	76.50352	490.1362	9.955578	355.998
2	476.2189	205.3215	373.4626	34.73023	512.6015	9.240692	451.2783
3	281.1161	128.2652	356.9214	17.75598	357.229	24.53412	502.7703
4	282.0215	97.87377	403.7635	115.1293	365.6729	69.52848	277.265
5	408.7222	66.35667	390.0368	39.84163	453.6129	24.34458	402.9048
6	342.6562	82.39136	380.1921	46.88293	277.658	4.300415	467.9623
7	298.0245	121.7625	426.5876	49.1578	483.1089	0.664677	604.8095
8	530.4128	62.69039	460.2662	35.74588	480.9814	-0.29982	611.2121
9	337.8998	110.2884	357.6968	56.14001	821.8025	-6.03955	704.5264
10	289.9703	136.7621	175.6026	82.11473	618.3369	-19.8202	583.138
11	430.2934	252.8979	97.81195	143.647	764.2847	-19.3846	609.3776
12	157.0767	190.8933	120.4808	148.359	522.554	-3.51394	582.9064
13	-1.09622	191.6934	108.3098	201.6387	371.1859	103.5287	470.1302
14	3.342617	223.892	97.69934	221.2814	629.3653	89.16297	409.0407
15	8.762849	154.8429	200.2568	206.4557	476.1318	32.78647	475.4213
16	-7.40391	172.3151	228.6454	206.5561	349.7401	21.88376	510.8433

（附录四中给出了 2006-5-31 至 2006-6-6 期间 P_A 的预测数据，其他机组由于原理相同，考虑到篇幅限制，故不再列出）

4.1.8 最终模型的确定

通过上述三种模型（分别为灰色预测、ARIMA、遗传神经网络）求解的各机组预测曲线准确率汇总如下表 4-12.1

表 4-12.1 三种模型求解的准确率

	PA	PB	PC	PB	P4	P58
灰色预测	96.94%	96.61%	96.48%	96.92%	97.25%	97.74%
ARIMA	98.59%	98.34%	98.13%	98.41%	89.90%	99.92%
遗传神经	97.59%	97.95%	98.37%	98.33%	98.44%	98.59%

将其作成图 4-12.2 各模型各机组预测曲线准确率




图 4-12.2 各模型各机组预测曲线准确率

由图中可以明显看出遗传神经网络的准确率最高，且波动最小，故最终模型选择遗传神经网络模型作为我们的预测模型。

4.2 问题二

是否误差就一定如我们所预期的那样，始终自适应地自我调节呢？为了进一步分析阐述误差的控制规律，下面特别对误差进行分析说明，下图是 PA 的预测误差分布如图




图 4-13 P_A 的预测误差分布

从误差分布图明显可以看出，误差被 3 个峰值分为 4 个区域，区域内误差在可控制范围，当误差超过这一可控制范围后，系统自动更新为实际监测数据，重新预测，误差重新减小到可控制范围，依此类推。由问题一中图 4-12、以及各个机


组的预测数据可以看出，预测误差具有一定的规律：

预测误差随着预测数据使用量的增多而最终呈增大趋势，并且机组汇聚会减小预测误差。设计的误差反馈控制模型就是，当误差超过规定允许范围时，系统将数据自动更新为实际数据，误差重新回到控制允许范围之内，如此循环。

从表 4-10 可以看出，P4 的准确率高于 PA、PB、PC 和 PD 单独预测时的准确率，P4 的预测效果明显优于 PA、PB、PC 和 PD 单独预测时的效果，同时，P58 的准确率高于 P4 的准确率，P58 的预测效果也明显优于 P4 预测的效果，这说明随着发电机组规模的扩大，可以减小随机波动。虽然规模的扩大能够提高预测的精度，增强发电系统的抗随机干扰能力，但规模的扩大意味着机组数量的增加，这种数量的增加将不利于发现因受干扰而出故障的机组，所以，在实际过程中应该采用一种折中方案。

4.3 问题三

传统的时间序列分析方法，如 ARMA 模型等，都要求时间序列具有正态分布，全局平稳、残差互不相关的特点，这使得传统的统计学方法在时间序列中很难准确地进行分析和预测。神经网络的预测法，由于其具有分布处理、自组织、自适应、自学习和容错性的优良特性，能较好地处理不确定、非线性的预测问题，在时间序列预测中得到较多的研究与应用，而一般的神经网络如 BP，RBF 只能处理静态对象，故本文提出基于动态神经网络的时间序列预测模型。本文不考虑其它因素的影响，时间序列的预测属于只单一考虑电功率在各时间的变化，即当前输出只取决于以前的输出这样的模型：



$$y(t) = f(y(t-1), \dots, y(t-d)), \text{ 无 } x, \text{ 有 } y \text{ 值, } NAR$$

4.3.1 模型的建立

为对时间序列进行预测，首先构造动态神经网络的结构及算法。

在此设计一个三层神经网络进行时间序列预测，第一层为单输入层，第二层为 L 个动态神经元，每个神经元的延时总次数为 M，传递函数采用双曲正切函数

$$\varphi(x) = \tanh\left(\frac{x}{2}\right) = \frac{1 - \exp(-x)}{1 + \exp(-x)}, \text{ 第三层为单输出层。}$$

误差修正采用“瞬时反传算法”设瞬时误差平方和为

$$\xi(n) = \frac{1}{2} e^2(n) \quad (25)$$

其中， $e(n) = d(n) - y(n)$ 为误差信号。学习的目标是使总体误差 $\xi_{\text{总}} = \sum_n \xi(n)$ 达

到最小。根据神经网络学习的梯度方法，有权值 w_{ji}^l 的修正公式为

$$w_{ji}^l(n+1) = w_{ji}^l(n) - \eta \varepsilon_j^{l+1}(n) x_i^l(n) \quad (26)$$

其中 w_{ji} 是连接神经元 i 和 j 的连接权值

4.3.2 模型的求解与结果分析

1)、数据的分割

本文选取 PA，2006 年 5 月 22 日—5 月 31 日的 960 组的数据其中 70%作为训练数据，20%作为验证数据，10%作为测试数据

2)、调用工具箱

使用 MATLAB2011a 的时间序列神经网络工具箱求解，nnstart——Time Series Tool 或者直接使用 ntstool。

3)、网络训练

将上述数据导入进去，选取 10 个隐藏层，4 个延时，进行训练，观测 Autocorrelation of error 判断模型的好坏。如果模型预测得很好，那么一个时间输出的误差跟另一个时间输出的误差应该没有任何关系，因为很独立。如果模型非常好，测 Autocorrelation of error 图中只有中间那条线，当然神经网络的模型不可能是一个非常理想的模型，故我们定义一个 95%的误差界限，如误差在这个界限之内，则此模型可以接受且相当理想。本文中的 Autocorrelation Of Error 如图 4-14。




图 4-14 Autocorrelation Of Error

4) 测试数据

将训练好的神经网络进行数据的预测,得 5 月 31 日的预测数据和真实数据对比图




图 4-15 P_A 5 月 31 日的预测数据和真实数据对比图

由图 4-15 可以看出除极少数点波动较大外,绝大多数点的误差都在小范围波动,预测效果很理想,从而验证了动态神经网络的时间序列预测模型的可行性,准确性。用类似的方法可以求得其它各机组的预测值,

表 4-10 各机组预测曲线准确率

	PB	PC	PD	P4	P58
准确率	98.24%	98.42%	98.37%	98.46%	99.43%

从各机组预测曲线的准确率来看,均相对于以上模型较优,也说明了动态神经网络的时间序列模型的可行性与正确性,而影响阻碍风电功率实时预测精度进一步改善的主要因素则是预测过程中是用预测得到的数据再去预测新的数据,随着使用预测数据量的增加,预测值的误差会越来越偏离实际值。

五、模型的优缺点评价

5.1、模型的优点

(1) 本文将灰色模型,神经网络等模型加入了预测精度的误差反馈控制,使得预测精度更高

(2) 时间序列预测法是一种定量分析方法,它是在时间序列变量分析的基础上,运用一定的数学方法建立预测模型,使时间趋势向外延伸,从而预测未来市场的发展变化趋势,确定变量预测值。

(3) 针对传统预测算法多步预测误差逐步增加的问题,提出了带修正因子的预测算法。

(4) 遗传算法来优化 BP 神经网络的初始权值和阈值, 使优化后的 BP 神经网络能够更好的预测函数输出

(5) 使用了动态神经网络时间序列预测, 克服了传统神经网络 BP、RBF 等只能处理静态对象的缺点。

5.2、模型的不足

(1) 时间序列模型一般只能用于短期预测, 对于中长期预测可能会出现误差累计情况。

(2) 动态神经网络的时间序列模型虽然效果好, 但是调节参数需花费大量精力。

六、参考文献

- [1]李俊芳、张步涵等. 基于灰色模型的风速-风电功率预测研究[J]. 电力系统保护与控制, 2010. 10
- [2]方江晓, 短期风速和风功率预测模型的研究[J]. 北京交通大学, 2010. 6
- [3]韩卫华、宁佐贵. 时间序列预测的动态神经网络方法[J]. 微机发展, 2004, 9
- [4]马千里、郑启伦等. 基于动态递归神经网络模型的混沌时间序列预测[J]. 计算机应用, 2007. 1
- [5]陈佳娟、陈晓光等. 采用计算机视觉进行孵化鸡蛋成活可能性的自动检测[J] 吉林大学生物资源工程学院, 长春 130025
- [6]卓金武、魏永生等. MATLAB 在数学建模中的应用[M]. 北京, 科学出版社 2011. 4

七、附录

附录一

%灰色预测的程序

函数文件 gm11.m

```
function [px0,ab,rel]=gm11(x0,number)
```

```
if nargin==1
```

```
    number=max(size(x0));
```

```
end
```

```
n=max(size(x0));
```

```
x1=zeros(size(x0));
```

```
for k=1:n
```

```
    for i=1:k
```

```
        x1(k)=x1(k)+x0(i);
```

```
    end
```

```

end
z=zeros(size(x0));
for k=2:n
    %z(k)=0.4*x1(k)+0.6*x1(k-1);
    z(k)=0.5*(x1(k)+x1(k-1));
end
y=x0';
y(1)=[];
b(:,1)=-z';
b(:,2)=1;
b(1,:)=[];
ab=inv(b'*b)*b'*y;
a=ab(1);
b=ab(2);
px0(1)=x0(1);
for k=1:number-1
    px0(k+1)=(1-exp(a)) * ( x0(1)-b/a ) * exp(-a*k);
end
temp=px0(1:n);
x0;
temp=(x0-temp)./x0;
temp=abs(temp);
rel=sum(temp)/(n-1);
主函数文件 gm11_main.m
clc
clear all
close all
load data.txt
data = data';
data = data(:)';
n = 16;
chushi_data = data(1:n);
i = n;
for j = 1:15
    yece_data = gm11(chushi_data,length(chushi_data)+1);
    yece_data(1) = [];
    chushi_data = yece_data;
end
while (1)
    yece_data = gm11(chushi_data,length(chushi_data)+1);
    yece_data(1) = [];
    disp('读入当前实际数据');
    input('请按回车键继续');
    shiji_data = data(i);





```


```

error = abs((yece_data(1)-shiji_data)/shiji_data);
wucha(i-15) = error;
if error<=0.3
    chushi_data = yece_data;
    disp('正常工作')
else
    disp('误差太大, 自动更新为实际数据');
    chushi_data = data(i-15:i);
    for j = 1:15
        yece_data = gm11(chushi_data,length(chushi_data)+1);
        yece_data(1) = [];
        chushi_data = yece_data;
    end
end
end
i = i+1;
end

```

附录二





附录三

%加入反馈控制的遗传神经网络

函数文件 gabpEval.m

```
function[sol,val]=gabpEval(sol,options)
```

```
global S
```

```
for i=1:S
```

```
    x(i)=sol(i);
```

```
end;
```

```
[W1,B1,W2,B2,val]=gadecod(x);
```

函数文件 gadecod.m

```
function[W1,B1,W2,B2,val]=gadecod(x)
```

```
global p
```

```
global t
```

```
global R
```

```
global S2
```

```
global S1
```

```
global S
```

```
for i=1:S1
```

```
    for k=1:R
```

```
        W1(i,k)=x(R*(i-1)+k);
```

```
    end
```

```
end
```

```
for i=1:S2
```

```
    for k=1:S1
```

```
        W2(i,k)=x(S1*(i-1)+k+R*S1);
```

```
    end
```

```
end
```

```
for i=1:S1
```

```
    B1(i,1)=x((R*S1+S1*S2)+i);
```

```
end
```

```

for i=1:S2
    B2(i,1)=x((R*S1+S1*S2+S1)+i);
End
A1=tansig(W1*p,B1);
A2=purelin(W2*A1,B2);
SE=sumsqr(t-A2);
val=1/SE;
主函数 ga_bp.m
clear all
close all
clc
warning off
nntwarn off
global p
global t
global R
global S2
global S1
global S
S1=10;
load data.txt
data = data';
data = data(:)';
x0 = data(1:32);
for i = 1:16
    day(:,i) = x0(i:i+15);
end
for i = 1:16
    dayn(:,i) = (day(:,i)-min(day(:,i)))/(max(day(:,i))-min(day(:,i)));
end
p=dayn(1:16,1:14)';
t=dayn(1:16,15)';
k=dayn(1:16,2:15)';
kn=k;
net=newff(minmax(p),[S1,1],{'tansig','purelin'},'trainlm');
net.trainParam.show=10;
net.trainParam.epochs=10000;
net.trainParam.goal=1.0e-28;
net.trainParam.lr=0.0001;
[net,tr]=train(net,p,t);
s_bp=sim(net,kn);
R=size(p,1);
S2=size(t,1);
S=R*S1+S1*S2+S1+S2;

```

```

aa=ones(S,1)*[-1,1];
popu=50;
initPpp=initializega(popu,aa,'gabpEval');
gen=100;
[x,endPop,bPop,trace]=ga(aa,'gabpEval',[],initPpp,[1e-6 1 1],'maxGenTerm',gen,...
'normGeomSelect',[0.09],['arithXover'],[2],'nonUnifMutation',[2 gen 3]);
[W1,B1,W2,B2,val]=gadecod(x);
net.IW{1,1}=W1;
net.LW{2,1}=W2;
net.b{1}=B1;
net.b{2}=B2;
net=train(net,p,t);
s_ga=sim(net,kn);
x_fangzhen = sim(net,p);
x_yuce = s_ga;
x_zong = x_yuce*(max(day(:,end))-min(day(:,end)))+min(day(:,end));
x0(1)=[];
predict = [x0 x_zong(end)];
figure
plot(day(1:16,16),'b-o');
hold on
plot(x_zong,'r*')
自适应控制函数文件 gabp.m
function predict = gabp(x0)
warning off
nntwarn off
global p
global t
global R
global S2
global S1
global S
S1=10;
for i = 1:16
    day(:,i) = x0(i:i+15);
end
for i = 1:16
    dayn(:,i) = (day(:,i)-min(day(:,i)))/(max(day(:,i))-min(day(:,i)));
end
p=dayn(1:16,1:14)';
t=dayn(1:16,15)';
k=dayn(1:16,2:15)';
kn=k;
net=newff(minmax(p),[S1,1],{'tansig','purelin'},'trainlm');

```

```

net.trainParam.show=10;
net.trainParam.epochs=10000;
net.trainParam.goal=1.0e-28;
net.trainParam.lr=0.0001;
[net,tr]=train(net,p,t);
s_bp=sim(net,kn);
R=size(p,1);
S2=size(t,1);
S=R*S1+S1*S2+S1+S2;
aa=ones(S,1)*[-1,1];
popu=50;
initPpp=initializega(popu,aa,'gabpEval');
gen=100;
[x,endPop,bPop,trace]=ga(aa,'gabpEval',[],initPpp,[1e-6 1 1],'maxGenTerm',gen,...
'normGeomSelect',[0.09],['arithXover'],[2],'nonUnifMutation',[2 gen 3]);
[W1,B1,W2,B2,val]=gadecod(x);
net.IW{1,1}=W1;
net.LW{2,1}=W2;
net.b{1}=B1;
net.b{2}=B2;
net=train(net,p,t);
s_ga=sim(net,kn);
x_fangzhen = sim(net,p);
x_yuce = s_ga;
x_zong = x_yuce*(max(day(:,end))-min(day(:,end)))+min(day(:,end));
x0(1)=[];
predict = [x0 x_zong(end)];
自适应控制主函数 gabp_main.m
clc
clear all
close all
load data.txt
data = data';
data = data(:)';
n = 32;
chushi_data = data(21*96-15:21*96+n-16);
i = 21*96+1;
count = 1;
flag = 0;
for j = 1:15
    yuce_data = gabp(chushi_data);
    chushi_data = yuce_data;
end
while (1)

```

```

yuce_data = gabp(chushi_data);
disp('读入当前实际数据');
input('请按回车键继续');
shiji_data = data(i);
error = abs((yuce_data(1)-shiji_data)/shiji_data);
wucha(i-1) = error;
if error<=0.2
    youxiao_data(count) = yuce_data(1);
    chushi_data = yuce_data;flag = 0;
    disp('工作正常')
    i = i+1;
    count = count+1;
else
    disp('误差太大，自动更新为实际数据');flag = flag+1;
    chushi_data = data(i-31:i);
    for j = 1:31
        yuce_data = gabp(chushi_data);
        chushi_data = yuce_data;
    end
end
if flag==3||count>7*96
    break
end
end
end

```

附录四

2006-5-31 当日 96 个时刻的预测值

	实际值	预测值	误差
1	249.0938	231.7951	17.29866
2	355.3125	415.0039	-59.6914
3	362.8125	470.3778	-107.565
4	323.8125	306.4045	17.40799
5	338.625	273.6791	64.94592
6	411.9375	412.0338	-0.09634
7	364.6875	325.8772	38.81027
8	405.375	302.6919	102.6831
9	496.2188	516.1319	-19.9131
10	375.6563	354.4917	21.16456
11	380.8125	271.3816	109.4309
12	410.625	489.1299	-78.5049
13	106.9688	138.4586	-31.4898
14	12	4.502876	7.497124
15	-3.5625	5.338757	-8.90126

16	10.78125	10.58962	0.191627
17	-1.875	-9.37683	7.501825
18	-2.25	-1.93824	-0.31176
19	-3.5625	-6.9229	3.360398
20	5.25	11.97687	-6.72687
21	27.375	36.61356	-9.23856
22	13.3125	17.1696	-3.8571
23	1.40625	-0.2344	1.640651
24	17.15625	21.35139	-4.19514
25	49.78125	49.66977	0.111475
26	45.9375	37.30332	8.634176
27	60	42.5663	17.4337
28	62.34375	66.56143	-4.21768
29	68.8125	301.4963	-232.684
30	34.59375	103.5454	-68.9517
31	14.625	-5.66371	20.28871
32	25.03125	6.218843	18.81241
33	30.1875	-52.3931	82.58065
34	21	-37.5694	58.5694
35	19.875	16.83799	3.037014
36	1.96875	156.5989	-154.63
37	56.53125	107.8464	-51.3151
38	55.21875	202.4125	-147.194
39	95.53125	17.26875	78.2625
40	74.15625	-4.75203	78.90828
41	54.46875	135.9888	-81.52
42	74.71875	473.4217	-398.703
43	388.875	120.7976	268.0774
44	264.6563	202.5135	62.14281
45	116.625	121.3557	-4.73069
46	150.2813	132.1604	18.12093
47	448.0313	401.8668	46.16448
48	148.875	126.7354	22.13958
49	155.25	176.0077	-20.7577
50	236.4375	264.7433	-28.3058
51	383.9063	371.1792	12.72712
52	189.75	202.674	-12.924
53	283.6875	355.157	-71.4695
54	238.4063	299.9087	-61.5024
55	188.625	168.5283	20.09667
56	196.5	208.4079	-11.9079
57	133.875	192.2093	-58.3343
58	92.25	1.336885	90.91311
59	118.3125	90.08809	28.22441

60	79.21875	211.0659	-131.847
61	41.90625	6.211917	35.69433
62	241.9688	323.1937	-81.2249
63	165.5625	255.5218	-89.9593
64	376.7813	399.2882	-22.5069
65	290.7188	524.9463	-234.228
66	301.125	197.5756	103.5494
67	487.9688	649.3143	-161.345
68	696.9375	722.0792	-25.1417
69	711.4688	661.0042	50.46463
70	626.8125	609.1611	17.65139
71	703.7813	786.3847	-82.6034
72	519.0938	543.4134	-24.3196
73	385.5938	352.2313	33.36247
74	667.5	704.5702	-37.0702
75	410.25	357.5419	52.70806
76	218.5313	121.6386	96.89271
77	204.75	134.312	70.43802
78	54.5625	46.86043	7.702073
79	204.5625	231.7586	-27.1961
80	183.4688	153.6959	29.77286
81	92.8125	186.9127	-94.1002
82	11.4375	46.86081	-35.4233
83	-4.125	-11.1377	7.01272
84	-1.6875	-42.5921	40.90456
85	11.625	0.269507	11.35549
86	-2.0625	-68.4543	66.39182
87	25.03125	-13.9438	38.975
88	49.40625	-57.1262	106.5324
89	43.6875	33.9774	9.7101
90	76.6875	12.22585	64.46165
91	139.3125	170.6528	-31.3403
92	109.5	121.8948	-12.3948
93	156.75	157.6399	-0.88993
94	144.6563	165.9167	-21.2604
95	180.75	151.4913	29.25874
96	153.0938	160.02	-6.92618


2006-5-31 各机组预测数据

	PB	PC	PD	P4	P58
1	164.0184	74.03793	130.8786	123.6638	6939.547
2	340.2838	326.1118	292.5408	1951.244	31535.45
3	336.5455	364.0551	281.9477	1327.042	17500.38
4	152.8247	472.1804	252.1851	1234.803	7392.162


5	262.2593	514.5568	319.3162	1044.999	12542.49
6	377.9018	398.4186	194.1326	1005.222	11485.46
7	180.08	280.1273	70.91724	856.836	8119.477
8	454.4158	451.5785	331.337	1286.526	15251.71
9	615.6857	319.1007	192.9925	1163.353	24080.11
10	648.0623	618.1176	364.0467	1806.828	28728.79
11	652.0763	539.7629	556.1939	2110.496	26091.07
12	601.5038	525.49	381.2009	2071.532	21136.62
13	275.0332	142.3661	76.80076	802.1672	8150.668
14	106.249	79.96637	26.70236	198.5453	3145.031
15	89.78651	-3.8825	55.47419	186.1276	1078.547
16	0.480895	12.28004	-38.5045	94.56209	476.8084
17	31.43909	-33.696	57.59756	33.7038	291.2118
18	0.173421	-12.633	-18.8341	-58.4835	-214.49
19	13.80372	-21.1252	-3.0037	43.71504	714.7624
20	27.97783	15.06205	7.17209	86.01295	772.5903
21	24.86533	-80.5053	17.71699	87.40336	223.2674
22	22.62121	-50.3219	43.46694	56.06997	826.8716
23	24.303	66.98597	-17.5222	55.06188	1201.787
24	18.86319	44.42228	60.86456	94.50259	-44.7287
25	62.14827	60.3525	57.48815	271.4024	2892.58
26	56.72621	47.77461	-65.815	357.1067	2008.229
27	38.54471	171.0176	-6.50496	187.2752	3179.388
28	214.731	152.4092	51.38913	563.309	8440.122
29	31.79569	62.68851	44.062	243.1713	1160.669
30	63.56869	90.00979	14.61563	-162.003	1386.173
31	56.40119	1.174408	-79.9859	137.0435	1514.24
32	-28.0623	88.53041	27.62489	-11.4354	556.4246
33	53.51244	45.56446	9.948523	112.3542	337.9387
34	84.12431	43.77838	111.9197	138.0736	-569.295
35	22.88034	182.107	30.89711	126.5532	1456.173
36	-17.9313	5.673434	36.91599	127.7632	3327.997
37	17.63225	55.45762	74.98221	627.1604	3003.004
38	29.03679	253.4343	-79.2128	197.6483	5221.669
39	176.5684	-19.1158	172.6105	612.5357	6945.815
40	388.8407	279.0534	13.08684	720.9417	5300.164
41	164.9917	309.7272	32.59075	580.8444	7785.316
42	60.27433	350.9192	329.9059	1178.771	8644.144
43	59.11604	216.3561	229.3618	877.9021	10900.24
44	352.8834	538.3801	385.5625	1680.453	14450.42
45	293.7943	323.3239	215.2167	1018.685	13585.39
46	156.7512	270.5105	256.5176	844.3446	13083.11
47	426.9165	334.9007	103.305	1391.646	15032.76

48	450.3885	172.8252	143.2777	907.4	11432.24
49	103.777	208.2985	194.854	688.7123	10272.41
50	92.99504	158.9731	92.59726	347.4636	7114.943
51	108.7544	13.64174	166.5616	609.2197	9406.175
52	245.6768	216.3408	141.0177	821.5121	9828.09
53	135.5705	20.00995	90.14999	542.5606	6944.6
54	267.3252	216.4933	225.6486	1001.465	10000.19
55	210.4514	180.2365	103.7902	572.86	5986.543
56	95.94654	93.24635	242.2516	742.6019	9971.178
57	174.9767	53.20127	347.6517	669.3211	8528.816
58	264.2628	294.8273	-27.3006	663.9079	6861.816
59	311.942	483.687	227.2807	1191.213	13611.27
60	285.9654	68.28074	386.3337	853.198	10761.94
61	293.1731	237.6143	273.8193	766.099	9710.982
62	194.7321	400.548	223.1775	666.9021	13722.26
63	157.933	409.418	61.74082	812.6647	5485.867
64	806.5872	338.265	228.323	1761.855	17666.85
65	239.0878	216.7407	180.2421	1281.351	20673.28
66	474.8738	400.4852	392.8542	1609.424	21446.04
67	635.2109	484.8644	398.7032	2084.271	21339.26
68	567.3898	376.7451	602.5505	2755.039	29728.27
69	790.759	795.1632	667.8127	2914.804	30592.82
70	519.121	902.6891	798.8607	2793.228	32324.64
71	545.314	650.3322	730.7063	2470.906	31100.43
72	737.388	445.3304	395.543	2196.5	26367.37
73	430.8304	594.6893	387.524	1505.576	20958.2
74	294.1108	353.4143	73.83516	1745.8	18044.35
75	520.4868	523.119	283.008	1607.474	18323.62
76	236.1819	221.8056	244.9628	1368.275	10651.01
77	67.92437	78.74413	106.1507	350.7097	5456.762
78	114.5148	164.2431	99.25531	402.0359	6411.126
79	145.4157	208.5298	202.9053	723.4238	9288.038
80	210.0695	213.8443	167.0425	773.2356	8557.574
81	152.3206	206.0262	137.1394	599.3665	6240.699
82	36.0794	111.4297	21.92818	261.8768	3065.368
83	101.9298	45.03266	43.62862	81.5615	2442.116
84	56.41394	50.62475	80.3618	63.93743	1308.519
85	86.14811	33.27821	-0.99666	81.54566	1722.389
86	35.55952	-8.14762	-4.79006	-5.65587	303.0236
87	-40.1866	39.48468	10.89493	-42.8275	-2645.45
88	0.688148	2.250103	-28.0857	33.46468	1692.591
89	0.383125	36.41858	14.63361	127.9626	3925.099
90	138.2499	117.0538	118.8757	457.3023	4923.835


91	159.0891	127.4991	156.5827	668.482	7356.768
92	122.1184	142.4891	123.6522	498.7025	6634.804
93	137.6052	102.3659	128.185	434.2818	6204.723
94	118.6456	111.5096	84.66448	513.6147	7705.373
95	175.895	215.6195	120.7372	839.4516	8004.484
96	143.901	203.4348	91.18313	589.4448	5429.915




PB




PC



PD



P4




P58

PA2006-5-31 至 6-6 预测数据

	5-31	6-1	6-2	6-3	6-4	6-5	6-6
1	396.0809	268.4878	348.4763	76.50352	490.1362	9.955578	355.998
2	476.2189	205.3215	373.4626	34.73023	512.6015	9.240692	451.2783
3	281.1161	128.2652	356.9214	17.75598	357.229	24.53412	502.7703
4	282.0215	97.87377	403.7635	115.1293	365.6729	69.52848	277.265
5	408.7222	66.35667	390.0368	39.84163	453.6129	24.34458	402.9048
6	342.6562	82.39136	380.1921	46.88293	277.658	4.300415	467.9623
7	298.0245	121.7625	426.5876	49.1578	483.1089	0.664677	604.8095
8	530.4128	62.69039	460.2662	35.74588	480.9814	-0.29982	611.2121
9	337.8998	110.2884	357.6968	56.14001	821.8025	-6.03955	704.5264
10	289.9703	136.7621	175.6026	82.11473	618.3369	-19.8202	583.138
11	430.2934	252.8979	97.81195	143.647	764.2847	-19.3846	609.3776
12	157.0767	190.8933	120.4808	148.359	522.554	-3.51394	582.9064
13	-1.09622	191.6934	108.3098	201.6387	371.1859	103.5287	470.1302
14	3.342617	223.892	97.69934	221.2814	629.3653	89.16297	409.0407
15	8.762849	154.8429	200.2568	206.4557	476.1318	32.78647	475.4213
16	-7.40391	172.3151	228.6454	206.5561	349.7401	21.88376	510.8433
17	9.352893	175.6806	85.45539	235.248	254.5746	20.57104	391.4927
18	-7.93044	105.7482	0.633977	227.7412	163.452	39.93563	351.705
19	15.79559	103.7858	0.508341	191.4971	156.3402	2.887345	294.6933
20	30.61731	169.0893	-3.79829	138.2423	228.4645	25.59246	360.8726
21	10.69236	56.05857	1.099312	41.09926	312.2365	53.87132	250.7768
22	0.49449	6.693173	-1.32581	-2.78291	276.1558	60.93512	145.8757
23	24.50723	28.42364	-5.82213	6.437499	197.5286	18.45523	215.5948
24	55.63507	25.91426	-7.48575	2.687412	221.7616	10.26143	213.7562
25	51.06541	22.4137	23.2306	-7.05381	103.7286	-1.07229	69.78717
26	49.73883	3.280393	7.966471	4.475623	210.8281	0.971962	53.83164
27	69.15613	-9.74976	14.36119	8.655208	258.4506	-2.6404	-5.41963
28	281.0961	-8.76864	-4.45794	3.843144	212.0249	-6.69159	227.8438
29	26.85124	6.571733	-2.96332	-2.20816	90.08546	10.69505	327.0578
30	-19.7401	-24.5161	15.4305	-1.98468	181.8166	-2.4333	232.1981
31	77.25462	-1.67454	77.41011	19.70742	101.7969	-1.76297	389.8206
32	-27.0902	28.19993	69.93287	4.803558	80.26869	-0.44248	491.7295
33	-196.811	114.843	3.724238	-73.6889	46.10771	-0.32166	198.964
34	-58.6962	26.90572	-12.0992	-11.1696	-3.55554	-1.09865	461.6676
35	166.5695	54.42486	-10.8317	46.94255	46.14459	-2.55103	130.7914
36	31.67191	67.03814	-0.56098	-2.03376	142.7035	-2.93247	573.1173
37	179.7873	59.33717	-7.67886	-181.396	104.6806	0.040581	643.1682
38	-3.20959	9.772097	-1.98549	-26.4122	99.38691	-2.02793	678.3784
39	48.3438	58.10572	3.917228	325.7558	62.62464	-2.36455	458.347
40	248.8696	138.4023	-7.66955	56.66242	214.4767	-0.95263	715.5613
41	410.9485	162.1795	44.69693	-237.82	138.3411	-2.02225	683.382

42	53.6414	203.5247	75.69216	-219.829	325.5433	-0.06878	847.1836
43	195.8059	100.8938	43.28559	599.0346	15.09163	-1.24124	533.1797
44	117.0189	444.4404	129.0781	175.8719	57.19533	-0.8896	642.1409
45	144.892	293.652	162.4746	312.9128	28.74039	-0.25362	857.9964
46	464.7197	185.4815	-6.79023	46.69645	161.7606	15.57236	806.0215
47	138.6718	131.8503	195.3481	48.07041	59.76949	-0.68814	372.0621
48	117.8189	132.6089	203.0339	64.93852	379.279	5.762894	693.6127
49	238.7133	242.3309	47.6291	19.95416	361.8681	-3.81075	839.9055
50	372.1581	114.4896	216.3247	94.45727	40.91507	-4.79214	841.4755
51	205.9248	229.759	-18.5019	81.73652	73.51777	0.007417	856.9143
52	349.4885	182.55	69.90024	42.98345	254.7669	-31.078	824.4359
53	317.6183	98.9585	-1.547	218.7739	67.7354	23.84672	836.1916
54	225.7832	286.0391	-81.4082	151.2042	354.5773	-15.5214	834.4171
55	158.2362	168.5406	26.26946	153.7777	37.5981	12.28972	813.6256
56	150.9372	138.2766	136.4286	90.8034	14.03675	79.51406	838.8065
57	77.60206	404.7207	129.1516	143.5607	26.62897	236.8696	835.1091
58	89.85406	284.1205	197.7985	-52.752	5.175741	66.55048	831.9605
59	234.4074	290.0035	276.1722	56.96092	26.42125	43.33374	840.1463
60	57.75867	208.9621	315.5078	25.95521	62.28659	-71.6011	835.5802
61	374.9962	320.356	210.5422	47.52934	-6.67997	-7.7142	829.7559
62	318.4742	94.75941	432.1662	132.0377	131.0969	57.94735	830.0492
63	478.834	73.97207	212.3319	0.037481	-11.0746	135.4172	757.6313
64	557.2071	408.6301	313.4522	87.60277	32.90157	46.26196	838.9256
65	302.5948	613.2137	347.0561	233.5759	-32.2409	90.88298	841.4761
66	583.6539	455.4433	584.1519	285.0662	47.01549	119.7899	837.5853
67	676.6504	243.9591	389.1572	97.04815	-36.6964	27.08823	830.8012
68	695.6917	111.9983	264.0403	281.3786	29.44312	59.83498	849.7591
69	615.9161	309.9057	84.95532	232.5279	-35.6932	-41.0856	590.3785
70	783.538	245.1128	33.01618	222.1145	22.48776	45.5512	883.1034
71	486.9891	68.86101	91.65474	366.4751	54.70021	133.0637	650.9131
72	357.4093	75.32575	200.7023	630.1123	48.92086	83.23752	149.725
73	784.4057	150.4723	427.913	219.975	24.6037	53.06237	400.8144
74	394.9615	166.3734	871.0173	347.6709	41.13351	90.57993	243.2795
75	178.4481	302.3922	842.7952	109.0672	29.24286	125.6081	1090.721
76	160.6999	312.3408	809.5073	109.8711	126.8594	159.8502	1098.022
77	68.50553	417.0149	809.915	-123.412	69.63128	176.6152	707.1401
78	188.1784	625.4148	831.9821	150.2995	56.77379	203.2467	1088.529
79	137.8523	383.7183	859.2591	72.65877	87.0664	147.387	1006.322
80	107.2763	510.3249	841.0844	167.7507	119.5401	146.3217	191.2228
81	66.21869	522.7628	889.7059	292.5905	136.8626	323.5755	841.6875
82	5.801817	630.0404	389.2275	325.14	372.923	206.2935	843.75
83	-40.0028	813.4485	81.23577	536.9495	387.3692	375.3417	599.1563
84	9.413464	788.1067	263.6915	319.6102	311.1784	263.5292	143.5313

85	-31.614	499.7963	73.48978	514.8828	411.1916	442.7995	30.9375
86	-5.84174	361.9239	207.7754	470.9011	316.4545	414.2001	65.90625
87	37.49331	475.915	69.9892	541.9406	240.6343	515.4689	-2.25
88	7.233734	337.1216	32.47095	802.6376	157.9914	437.2663	1.59375
89	90.74271	350.9372	79.98691	801.3377	115.8369	303.1711	-1.875
90	233.1099	499.1608	54.16646	755.1195	132.4601	172.0366	92.625
91	113.3268	374.3867	30.0905	661.1999	160.3837	117.3613	386.625
92	155.3573	520.9065	89.23116	530.7018	74.51822	125.7449	194.1563
93	178.451	262.7747	92.28649	431.5145	101.0174	348.2024	128.3438
94	157.1037	427.7555	80.52721	364.8148	69.40337	423.6613	134.625
95	158.3397	239.2603	-11.206	468.9178	70.60204	307.5156	131.4845
96	396.0809	268.4878	348.4763	76.50352	490.1362	9.955578	355.998



操作界面