

食品卫生安全保障体系数学模型及改进问题研究

薛彦红¹, 陈建军², 张亮²

(1 东南大学 集成电路学院, 江苏 南京 210013)

(2 东南大学 信息科学与工程学院, 江苏 南京 210096)

摘要: 论文研究了食品卫生安全保障体系的数学模型, 阐述了各种模型的建立方法. 在建模过程中, 探讨解决了一些改进模型的理论问题. 主要工作包括: 1、通过改进CAC食品分类标准, 给出了一种有效的适用于抽样调查的食物分类方法, 在此基础上建立了膳食模型; 2、给出了污染物分布模型及建模方法, 提出了一种由少量样本数据迭代地外推随机变量整体概率密度函数的算法, 讨论了由不同区域的监测数据估计全国总体分布的问题, 并给出了一种解决方案; 3、建立了风险评估模型, 探讨了输入数据不配套时, 抽样调查数据的衔接问题. 提出了一种新的污染物摄入量的99.999%的右分位点的估计方法.

关键词: 膳食模型; 污染物分布模型; 风险评估模型; 食品卫生安全

1 问题的背景与分析

“民以食为天, 食以安为先”, 食品卫生安全关系国计民生, 关系经济繁荣和社会稳定. 近年来, 随着人民生活水平的不断提高, 食品卫生安全问题更加受到人们的关注. 我国是人口众多的发展中国家, 食品消费量大, 而粮食生产, 加工分散, 因而食品卫生安全监控难度较大. 学习借鉴欧美国家食品卫生安全监控的做法, 建立膳食暴露评估数学模型, 用以处理调查或检测数据, 对公共食品卫生安全做出评估应该是一条可行的途径.

美国和欧盟已经建立了有关模型并且开始使用, 用实践证明了其可行性. 但是模型的建立和使用还存在着很多困难和问题. 在建立膳食模型时需要设计合理的抽样调查方案, 并由抽样数据建立比较准确的人群食品摄入量模型. 污染物分布模型的建立面临的问题包括: 怎样利用抽样率很低的随机抽样数据建立模型; 怎么由随机变量取值大于某一数值的部分样本数据再加上其他可以利用的信息估计出这个随机变量的整体分布. 风险评估模型就是利用前两个模型的结果对全国、某个地区、某类食品的安全状况做出评价. 它要解决两个模型中的调查对象和调查食品分类的不配套问题, 还需要提高全体居民某项污染物摄入量的99.999%的右分位点的估计精度.

2 人群食物摄入量模型及建模方法

2.1 抽样调查中食物的分类方法

我国居民消费的食物种类非常复杂, 包括: 主食、肉类、蔬菜、水果、水、饮料、各种调味剂和经过加工的食品, 细分将达数千种以上. 在实际调查过程中如果详细地分类, 其调查工作量太大, 得到的数据也会难以处理, 不利于描述食物摄入量的分布情况; 而如果随意粗糙进行分类, 则将影响调查的精度, 因此需要根据污染物分布模型的数据合理设计抽样调查中食

物的分类办法

我们这里参考的食物分类方法是国际食品法典委员会(CAC)食品与饲料分类标准^[7]。1989年,第18次法典大会采用了这一分类系统,将它作为《食品中的农药残留建议指南》的第4部分。目前,CAC已将整个食品和动物饲料产品分类系统纳入了计算机管理系统,这样所有农药残留方面的法典都可以通过程序链接到该系统。现在至少有4000种食品和饲料产品已包含在该数据库中。

食品法典分类标准是按4个层次来进行食品和动物饲料分类的。首先,按照原料来源及是否经过加工分为A、B、C、D、E 5个等级。这5个等级分别是A级植物来源的初级食品(包括5种类型)、B级动物来源的初级食品(包括5种类型)、C级初级饲料(包括1种类型)、D级植物来源的加工食品(包括4种类型)、E级动物来源的加工食品(包括4种类型)。其次,在等级划分的基础上,根据产品特征共划分为19个类型。各大类中根据农药残留相似性再分为不同的组,如水稻、麦类、杂谷类、豆类、薯类等,分类标准的每个组中都包含各种推荐指标,如潜在农药残留量、作物和动物在正常情况下的消费量以及应用农药最大残留限量的商品比例等。组是由不同的商品名称组成,食品和饲料法典分类标准对商品特征描述比较清楚,包括数字编号、字母代码、产品名称、拉丁名称、产品特征等。数字编码包含的信息包括:等级、类型、分组、字母代码、数字代码和特征描述等。

通过以上的描述可以看出CAC分类标准较多地考虑了食品中的农药残留情况,这正好符合食品安全评估的要求。另外,CAC分类法是按照四个层次来进行分类的,分别是等级、类型、组和商品名称。这种分类方式有利于不同时期,不同地域,不同种类的抽样数据之间,食物摄入量模型与污染物分布模型之间数据的相互转换和组合,所以在污染物分布模型的数据分类不一致时,膳食模型的数据可以方便地与其匹配。因此这种分类方式具有较好的特性,我们在此建议采用CAC分类标准对食物进行分类。但是,针对这里的具体的实际问题,需要在两个方面对CAC分类标准进行改进。首先CAC的分类标准是针对食品和饲料的,而我们要评估的是食品安全问题,所以可以将其中对饲料的分类去除。具体地说就是可以只考虑其5个等级中的4个(A、B、D、E)。其次,CAC分类方法的分类标准是农药残留,由于现实生活中的食品污染的多样性,所以有必要对其它的污染源加以考虑,例如污染行业的污染物排放数据和食品卫生安全监测部门日常对水、农贸市场和大宗食品中污染物的抽查数据以及进出口口岸的检测数据等。这样将更加有利于人群食物摄入量模型与污染物分布模型之间的匹配。因此我们这里给出的食品的分类方法的总体框图表示在图1中。

2.2 人群食物摄入量模型的建立方法

人群食物摄入量模型是不同情况人群各种食品的日均摄入量,我们的模型要考虑人群的情况,以及各种食品的情况。我们的建模方法是:先分别针对某种食品建模;而全部种类食品的摄入量模型则通过将各种食品按照其与总量之间的比例关系加权,再求和而得到。对每种食品的建模又需要按人群的不同情况来分别建模。具体地说就是,按性别(男、女),年龄(分成几个不同的年龄段),城乡(城市、农村),地区(先对各个地级市分别建模,再按其人口比例进行加权生成全省的模型;按同样的方法由各个省模型组成全国的模型)。这种建模方法的优点是:由于我们掌握了各个单独分量的摄入量模型(比如各个地区,各个年龄段或性别情况),因此当我们需要评估某个地区或者某种特征人群的模型时,可以直接利用其相应的摄入量模型,而不需要用其它模型来近似,精度可以做到更高。另外一个优点是我们按照各




图1 食物分类方法框图

子集类摄入量模型相应样本数之间的比例来加权求和,可以保证最后所得到的估计量是总体目标量的自加权无偏估计.

对于某种具体的食品而言,国家卫生部、科技部和国家统计局在2002年组织了“中国居民营养与健康状况调查”.调查队在全国31个省、直辖市、自治区的132个调查点中选取23470户进行膳食调查.膳食调查采用连续3天24小时回顾询问法调查居民所有摄入食物,用“称重法”调查家庭肉及肉制品消费量.部分种类食品的人日均膳食摄入量见表1.对所调查食品日均膳食量的统计结果显示,绝大多数食品的日均膳食量摄入水平服从正态分布,其中我国居民日均摄入熟肉制品量的分布情况见图2.

表1 2002年全国营养调查部分食品人均膳食摄入量数据

食品类别	每日消费量(g)	标准差	消费人群比例
蔬菜	280 9259699	168 8339531	0.99
水产品	87.91046272	70.91503249	0.34
生猪肉	82.33422109	65.46614034	0.65
生禽肉	66.22148968	53.72746529	0.18
生羊肉	52.50807958	42.42764754	0.038
熟禽肉制品	50.41941748	38.8737811	0.016
数畜肉制品	47.23153693	42.26154557	0.099
生牛肉	47.03479886	41.88530612	0.086




图2 熟肉制品人日均摄入量分布图

我们这里考虑由各个省调查数据来估计全国摄入量模型的方法, 假设第 i 个省的摄入量模型为:

$$f_i(x) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(x-u)^2\right\}, & x \geq 0 \\ 0 & x < 0 \end{cases} \quad (1)$$

其中, 随机变量 x 为某类食品的日均摄入量, 看成是随机变量, u 为该食品日均摄入量的平均值, σ 为日均摄入量的方差 s 是将该不完整的正态概率分布归一化的常数, 它等于该分布在所有随机变量范围上的面积:

$$S = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} \exp\left\{-\frac{1}{2\sigma^2}(x-u)^2\right\} dx \quad (2)$$

则该类食品全国的摄入量模型通过下式计算:

$$f(x) = \sum_{i=1}^N W_i f_i(x) \quad (3)$$

其中: $W_i = M_i/M$ 为该省的总人口数 M_i 与全国的总人口数 M 之间的比值, 即为该省的权; N 为全国的省级行政单位的数目.

我们对表1中所列的调查结果进行了仿真 首先根据表1中该食品的调查结果生成样本数据, 然后用拟合的方法估计其概率密度分布 仿真的结果见图3和图4, 其中各图分别对应着蔬菜和水产品的概率密度分布




图3 蔬菜的概率密度估计




图4 水产品的概率密度估计

3 污染物分布模型及建模方法

3.1 基本模型的建立及求解

污染物分布的特点有: 第一、污染物含量不会是负的, 所以概率密度函数分布在右半平面; 第二、污染物分布是左偏态, 即均值左边的概率远大于均值右边的概率; 第三、食品绝大多数都是污染物含量很低的, 所以概率密度函数集中分布在污染物数值小的区域; 第四、对于某种待测食品, 被检测污染物的数值为零的情况也很少, 所以概率密度函数的峰值不在随机变量取零时.

由实测的数据得到频率直方图, 运用最大似然估计得到适合的参数 考虑到污染物种类很多, 如果只对一种分布采用最大似然估计, 误差会很大 我们采用对一族函数采用最大似

然估计, 这族函数满足污染物分布的四个特点, 这样就可以提高估计的精度

第一、直方图粗略估计: 对于一组实测得到的样本 $(z_1, z_2, \dots, z_{n_{sp}})$, 其中 n_{sp} 为样本容量在统计学中, 有诸多方法可以在直观上给出概率密度函数的粗略估计, 其中最常用的是绘出数据的频率直方图 众所周知, 由于直方图的形状往往随着划分区间的大小和数目而产生很大的差异, 因此, 它仅能提供一个相当粗疏的估计 事实上, 这一问题与 χ^2 检验中遇到的问题本质上是相同的 虽然如此, 统计经验表明, 当选取的分段数目适当的时候, 直方图可以大致反映概率密度函数的粗略形状 鉴于此, 在本文中给出密度函数估计的同时, 亦绘出频率直方图以资参照 根据已有大量统计分析给出的经验, 本文中的直方图区间划分数目 k 取为 u , 即 $k = 1 + \log_2 n_{sp}$ 例如, 当样本量 $n_{sp} = 52$ 时, 划分区间数目可取 6

我们先获得样本频率分布曲线, 对连续型随机变量 x , 观测 n 次, 把样本的取值区间划分成若干等间距小区间 $(x_1, x_2], (x_2, x_3], \dots$, 样本值落入 $(x_k, x_{k+1}]$ 的个数为 n_k , 则样本频率为:

$$f(x_k) = \frac{n_k}{n} \frac{1}{\Delta x} \quad (4)$$

其中 $\Delta x = x_{k+1} - x_k$, $f(x_k)$ 曲线为样本频率分布曲线, 简称频率曲线 当 $n \rightarrow \infty$, $\Delta x \rightarrow 0$ 时, $f(x_k)$ 趋向于概率密度

第二、最大似然估计: 设描述总体的随机变量 X 的概率密度函数为 $f(x, \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 是未知参数 总体的样本 $X_1, X_2, \dots, X_n$ 的测量值为 $x_1, x_2, \dots, x_n$, 其联合密度是 $\theta_1, \theta_2, \dots, \theta_k$ 的函数, 又称似然函数, 记为:

$$L(\theta_1, \theta_2, \dots, \theta_k) = L(\theta_1, \theta_2, \dots, \theta_k, x_1, \dots, x_n) = \prod_{k=1}^n f(x_k, \theta_1, \theta_2, \dots, \theta_k) \quad (5)$$

若存在 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 使下式成立:

$$L(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) > L(\theta'_1, \theta'_2, \dots, \theta'_k) \quad (6)$$

则称 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 是 $\theta_1, \theta_2, \dots, \theta_k$ 的最大似然估计值, 其中 $\theta'_1, \theta'_2, \dots, \theta'_k$ 是 $\theta_1, \theta_2, \dots, \theta_k$ 任意其它可能的取值 由于似然函数式是多个因子的乘积, 利用对数 $\ln L(\theta_1, \theta_2, \dots, \theta_k)$ 进行计算比较方便, 并且 $\ln x$ 是 x 的单调上升函数, 故 $L(\theta_1, \theta_2, \dots, \theta_k)$ 与 $\ln L(\theta_1, \theta_2, \dots, \theta_k)$ 有相同的极大点, 从而 $\theta_1, \theta_2, \dots, \theta_k$ 的最大似然估计值可由下列方程组求得:

$$\begin{cases} \frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_k)}{\partial \theta_1} = 0 \\ \frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_k)}{\partial \theta_2} = 0 \\ \vdots \\ \frac{\partial \ln L(\theta_1, \theta_2, \dots, \theta_k)}{\partial \theta_k} = 0 \end{cases} \quad (7)$$

在获得样本以及直方图以后, 我们采用最大似然估计来拟合数据, 由于污染物种类繁多, 若用一种分布来拟合, 则误差很大, 对于某一污染物, 我们采用多种分布模型进行拟合, 这样就提高了估计分布的精度

基于污染物分布的特点, 我们给出四类污染物分布模型: Nakagami 分布、对数正态分布、Weibull 分布、Gamma 分布 采用 matlab 程序, 可以得到各种分布的参数, 从而找到对于该模型一种最优的分布 这样就得到了基本模型

3 2 基本模型的求解

下面我们以汞污染样本为例, 详细地描述建模过程

- Step 1 对数据的分析: 我们把汞污染数据用概率直方图来表示, 如图5 所示:
- Step 2 依次依据六类污染物分布模型对样本数据进行拟合, 获得拟合结果




图5 原始数据




图6 用不同分布拟合结果

仿真结果的性能统计如表2 所示:

表2 不同分布的拟合结果统计表

Distribution	Log likelihood	Domain	Mean	Variance
Nakagami	- 592 768	$0 < y < \ln f$	1. 73503	0. 194237
Lognormal	- 573 739	$0 < y < \ln f$	1. 73295	0. 203774
Weibull	- 648 255	$0 < y < \ln f$	1. 72663	0. 239283
Gamma	- 578 096	$0 < y < \ln f$	1. 73277	0. 194404

Step 3 由上表我们可以明显看出Lognormal 是最优的, 所以我们这次采样数据用Lognormal 分布拟合, 误差较小

由于污染物种类多种多样, 所以拟合的分布和参数也各不相同 我们采用了一类分布(Nakagami 分布、对数正态分布、Weibull 分布、Gamma 分布), 来拟合不同的数据, 提高了拟合的精度

3.3 对基本模型的进一步优化

偶然抽查数据和监测性检验数据包含所有被检测食品的污染物含量, 而符合性检验只有“被检出”的食品的污染物含量, 没有“未检出”食品的污染物含量, 如果把“未检出”食品的污染物含量作为零, 那么我们得到的污染物分布模型会有很大误差

对于检测结果来说, 因为对“已检出”的食品进行了全部检测, 所以样本频率分布函数的右边比较精确, 但是在食品安全的情况下“未检出”的数据远比有具体数值(“已检出”)的次数多, 或者说数据经过筛选, 左边数据不及右边数据精确

为了充分利用“未检出”食品数据, 我们采用将利用 2% 的随机数据, 以及“未检出”食品数据对左边的数据进行加权处理, 经过数次迭代逼近理论分布

对存在“未检出”食品数据进行假设: 第一、认为符合性检验的中“已检出”数据的污染物含量是真实的, 而“未检出”食品数据的污染物含量认为为零 第二、偶然检测数据是针对符合性检测中未检测部分进行的 第三、虽然偶然抽查数据是总体数据量的 2%, 但对实际抽样方案来说, 由于总体的数据量很大, 则偶然检测数据量应该不会太少 我们把满足上述假设的数据记为“实际数据”

3.3.1 直接利用污染物大于某一数值的样本拟合

如果直接利用随机变量取值大于某一数值 t 的部分样本数据来估计整体的分布则性能不好, 如图 7 所示:




图 7 用部分样本数据来估计整体的分布的效果

图 7 中, 红线是用Lognormal 分布来拟合原始数据, 而蓝线是用Lognormal 分布来拟合后 7% 数据(实际情况下可能比 7% 更小), 由此可以清楚的看到误差很大

3.3.2 新型的迭代算法来拟合整体

我们提出一种新的迭代算法来拟合整体概率密度函数的分布 下面详细描述算法的步

骤, 并给出实验仿真的结果 算法描述:

- 1) 数据输入: 根据实际采样的样本, 画出频率直方图
- 2) 初始分配: 把随机变量在零处的样本分配到 2% 的偶然监测数据中去, 这些数据和“已检出”数据组成新的统计数据 X_0
- 3) 初始拟合: 根据最大似然估计 (基本模型) 来拟合数据 X_0 , 得到概率密度函数 f_0
- 4) 修正分配: 根据上次得到的概率密度函数 f , 把随机变量在零处的样本分配到 2% 的偶然监测数据中去, 这些数据和“已检出”数据组成新的统计数据 X_i
- 5) 修正拟合: 根据最大似然估计 (基本模型) 来拟合数据 X_i , 得到概率密度函数 f_i
- 6) 判断迭代次数是否大于最大迭代次数 L , 若大于, 则执行 7), 否则转至 4), 开始下一次迭代
- 7) 结束

算法中, 初始分配的选取对整个迭代收敛速度, 最后的估计结果有相当大的影响, 如果有一定的先验知识, 初始分配可根据先验知识来假设 考虑到所有偶然检测采样点对分布曲线都有贡献, 所以我们取初始分配的比例是按照 2% 的偶然检测数据的分布

我们对该算法进行了仿真实验: 仿真条件: 理想数据服从 Lognormal 分布, “已检出”数据的污染物含量位于 99% 右分位点右边, 偶然抽查数据占总样本数的 2%.




图8 用Lognormal 分布拟合时第一次迭代的结果

从上图可以看出, 经过两次迭代, 概率密度已经很好的逼近理想数据的 Lognormal 分布曲线 仿真结果如表3 所示:

表3 迭代法仿真结果统计

名称	Log likelihood	Domain	Mean	Variance
理想数据	- 5339.97	$0 < y < \ln f$	1.70163	0.187185
第一次迭代	- 4927.59	$0 < y < \ln f$	1.68556	0.171308
第二次迭代	- 5323.74	$0 < y < \ln f$	1.70681	0.186405




图9 用Lognormal 分布拟合时第二次迭代的结果

我们的算法具有收敛速度快的优点, 在第二次迭代后一般都能获得较好的概率密度函数的分布

4 风险评估模型及建模方法
4.1 风险评估模型及其建立方法

风险评估模型是要求出全国或者某个地区某类人群对某些污染物的摄入量 而污染物的摄入量等于该人群食物摄入量乘以污染物在此类食物中的含量 假设对某种食品而言, 某类人群对其一天的摄入量为随机变量 X , 其分布为 $f_X(x)$ (即人群食品摄入量模型); 而每单位质量的该种食物中含有某类污染物的质量为 Y , 其服从分布 $f_Y(y)$ (污染物分布模型); 设该人群对这种污染物的摄入量为随机变量 Z , 则有, $Z = XY$, 我们要求概率密度分布 $f_Z(z)$ (风险评估模型). 如图 10 所示:




图10 风险评估模型建立示意图




图11 积分区间示意图

当两个随机变量的分布函数已知时, 如果它们的分布函数比较特殊或比较简单, 我们可以根据两个随机变量的密度函数按照现有的公式直接求出乘积的密度函数和分布函数 即假设通过前面的两个模型, 我们已经建立了食物摄入量(x) 和污染物含量(y) 的概率密度函数 $f_X(x)$ 和 $f_Y(y)$, 其联合概率密度函数为 $f_{X,Y}(x,y)$, 污染物的摄入量(z) 为这两个随即

变量的乘积 假设 x, y, z 的累积分布函数(CDF) 分别为 $F_X(x), F_Y(y), F_Z(z)$, 则有:

$$F_Z(z) = p(Z \leq z) = p(XY \leq z) = \iint_{y \leq z/x} f_{X,Y}(x, y) dx dy \quad (8)$$

我们假设食品摄入量的最大值为 $X_{\max}$, 而单位质量中污染物含量的最大值为单位质量 1, 所以我们可得到积分区间, 如图 11 所示, 则积分可以按三种情况来考虑:

$$F_Z(z) = \begin{cases} 0, & z \leq 0 \\ \iint f_{X,Y}(x, y) dx dy + \int \int_{y \leq z/x}^{\max} f_{X,Y}(x, y) dx dy, & 0 < z \leq X_{\max} \\ \iint_{y \leq z/x}^{\max} f_{X,Y}(x, y) dx dy & X_{\max} < z \end{cases} \quad (9)$$

则概率密度函数为上式的导数:

$$f_Z(z) = F'_Z(z) = \frac{dF_Z(z)}{dz} \quad (10)$$

上式即为风险评估模型

由文献[8], 我们可以用另外一种方法计算 z 的密度函数, 为:

$$f_Z(z) = \int_{-\infty}^{\infty} f_{X,Y}\left(\frac{z}{y}, y\right) \cdot \left|\frac{1}{y}\right| dy \quad (11)$$

然而有些随机变量(如污染物分布)概率密度函数比较复杂, 按照公式直接计算概率密度函数或分布函数往往无法得到最终结果 因为在按公式求两个随机变量乘积的密度函数时, 会遇到求函数积分问题 当积分表达式比较复杂时, 可能无法得到积分结果 所以我们采用随机模拟的方法来求解两个随机变量乘积的拟合分布函数

具体的算法过程为: 根据已经建立的食物摄入量 (x) 和污染物含量 (y) 的概率密度函数 $f_X(x)$ 和 $f_Y(y)$, 可以得到两组分别服从分布 $f_X(x)$ 和 $f_Y(y)$ 的随机样本 $x_1, x_2, \dots, x_n$ 和 $y_1, y_2, \dots, y_n$, 将两组随机数对应相乘得 $x_1y_1, x_1y_2, \dots, x_1y_n, x_2y_1, \dots, x_ny_n$, 这一组数据就可以看作是随机变量 $z = xy$ 同分布的随机样本, 然后对这一组随机数用直方图拟合的方法得出其拟合分布的密度函数 算法的基本原理图 12 所示




图 12 基于随机模拟的风险评估模型建立方法图




图 13 右分位点估计算法示意图

为检验我们所提算法的可行性, 我们做了仿真试验 首先在计算机上生成两组样本容量为 1000, 分别服从分布 $\text{normal}(280, 268)$ 和 $\text{lognormal}(0.5, 0.25)$ 的样本数 $x_1, x_2, \dots, x_{1000}$ 和 $y_1, y_2, \dots, y_{1000}$ 则可以得到随机数组 $x_1y_1, x_1y_2, \dots, x_1y_{1000}, x_2y_1, x_2y_2, \dots, x_{1000}y_1, \dots, x_{1000}y_{1000}$, 然后, 对得到的乘积样本进行直方图统计, 并对其进行最大似然拟合 仿真结果如图 14 所示

各种分布拟合的统计性能如下:




图 14 基于随机模拟的风险评估模型结果

表 4 不同分布的拟合结果统计表

Distribution	Log likelihood	Domain	Mean	Variance
Normal	- 72760.5	$-\infty < y < \infty$	525.789	122311
Nakagami	- 74018.7	$0 < y < \infty$	658.969	987236
Lognormal	- 71684.7	$0 < y < \infty$	515.585	132925
Weibull	- 71923	$0 < y < \infty$	521.026	142037
Gamma	- 72194.9	$0 < y < \infty$	525.789	183466

从上图以及表中所列的数据可以看出Nakagami分布非常好的拟合样本数据, 所以我们有理由相信, 风险评估模型是满足Nakagami分布, 即:

$$f(x) = 2\left(\frac{\mu}{\omega}\right)^{\mu} \frac{1}{\Gamma(\mu)} x^{(2\mu-1)} e^{-\frac{\mu}{\omega}x^2}, \omega > 0, x > 0$$

(12)

其中: μ 为形状参数; $\omega > 0$ 为尺度参数

4.2 建模过程中数据不配套时的解决方法

在风险评估模型时, 建立模型的输入是抽样率很低的随机抽样数据, 这两批数据通常是不配套的, 即人群食品摄入量模型中的调查对象极大可能不是污染物分布模型中被调查食品的消费者. 在这里我们受原问题中给出的思路的启发, 认为两批抽样调查是完全独立进行的. 在此假设下, 风险模型的建立问题就转化为在相互独立的膳食模型和污染物分布模型给定的情况下来估计随机变量——每个人每天某种污染物摄入量的问题.

前面我们已经建立了食物摄入量(x)和污染物含量(y)的概率密度函数分布, x 和 y 相互独立, 污染物的摄入量(z)为这两个量的乘积. 则有:

$$F_z(z) = \iint_{y \leq z} f_{x,y}(x,y) dx dy = \iint_{y \leq z} f_x(x) f_y(y) dx dy$$

(13)

上式中的第二个等式是由我们假设两批抽样调查是完全独立进行而得到的, 因此其分布是独立的. 并且对于 $0 < z < X_{max}$ 的情况, 则积分可以展开为:

$$F_z(z) = \iint_{y \leq z} f_x(x) f_y(y) dx dy$$

$$= \int f_Y(y) dy \int f_X(x) dx + \int_{-\infty}^{\max} f_X(x) \int f_Y(y) dy dx \quad (14)$$

则概率密度函数为上式的导数:

$$f_Z(z) = F'_Z(z) = \frac{dF_Z(z)}{dz} \quad (15)$$

上式即为在样本数据不匹配时的风险评估模型

在 x 和 y 相互独立的情况下, 式(11) 变为

$$f_Z(z) = \int_{-\infty}^{\infty} f\left(\frac{z}{y}, y\right) \cdot \left|\frac{1}{y}\right| dy = \int_{-\infty}^{\infty} f_X\left(\frac{z}{y}\right) f_Y(y) \cdot \left|\frac{1}{y}\right| dy \quad (16)$$

4.3 污染物摄入量99.999%的右分位点精度的提高

风险评估模型对食品安全进行评估是通过人群食物摄入量模型和污染物分布模型所提供的数据计算得出全国或某地区人群某些污染物每天摄入量的99.999%的右分位点, 并将其与食品卫生安全部门的安全标准进行比较, 如果右分位点小于安全标准, 则认为食品卫生状况是安全的. 因此我们更关心的是污染物摄入量99.999%的右分位点, 所以右分位点估计的精度是非常重要的问题.

针对直接估计99.999%的右分位点方法精度较低的缺点, 我们给出了一种新的估计99.999%右分位点的方法. 方法主要是在两个方面进行了改进来提高估计的精度: 一是不估计随机变量的概率密度函数, 而是对随机采样的样本进行排序来估计; 二是我们不是依据99.999%部分的样本数来估计右分位点, 而是估计尾部的0.001%的左分位点.

直接基于随机采样样本的右分位点的估计方法是基于Monte Carlo方法. Monte Carlo方法在数学上又被称为随机模拟(Random Simulation)方法. 随机采样(Random Sampling)技术或统计试验(Statistical Testing)方法, 它的基本思想是: 根据要解决的具体问题建立适当的概率模型或随机过程, 使其参数等于问题的解, 然后通过对模型或过程的采样实验来计算所求参数的统计特征或其近似值. 如今, 计算机的发展及其性能的提高使得Monte Carlo方法得到了广泛的应用.

直接基于随机采样样本的右分位点的估计方法的基本原理如图13所示. 如图所示, 图为随机变量 x 的概率密度函数曲线, 我们要估计 m 值, 使得 m 值左边的概率密度函数的积分(累计概率密度)占整个概率密度曲线积分面积的99.999%. 这里我们不是按照常规的方法先由抽样样本数据估计随机变量的概率密度函数曲线再积分. 假设随机抽样得到的样本数为 M , 先按照从小到大的顺序排列将抽样样本值; 然后找出其中的左边的99.999% M 个和其右侧相邻样本的分界线, 并取其中值为 m 的估值, 即假设随机变量样本在从小到大排列之后的从左边数第99.999% M 个样本值为 m_1 , m_2 是与 m_1 相邻且位于其右侧的样本, 则 m 的估计值定义为:

$$\hat{m} = (m_1 + m_2) / 2 \quad (17)$$

为了保证估计的精度, 对抽样的样本总数 M 有一定的要求. 这里要求左边的面积为99.999%, 即为0.99999, 精度至少是0.01, 所以需要的样本数至少为 10^7 .

考虑到这里具体情况的情况, 由前面建模的过程, 我们知道虽然 m 左边的积分面积比其右边大得多, 但左边的抽样样本数却是很有限制的, 因为这些数据很多都来自于复合性检验. 而右边的部分虽然其所占面积很小(只有0.001%), 但是其中的样本数却非常的多, 因

为所有的检验都会给出 m 右边的准确测量值 所以我们很自然的可以想到, 我们用 m 右边的数据来估计会得到更加准确的结果 所以这里我们的算法是: 对于 M 个随机抽样本值, 我们取右边 $0.001\%M$ 个样本, 即从右边数的第 $0.001\%M$ 个样本, 并找出与其相邻的左边的样本, 取两者之间的均值作为 m 的估计.

5 数据的分类标准不相同的问题

我们能够得到的调查数据很有可能是按照不同的方法来分类的, 例如不同地区, 不同时间所做的调查用到的分类方法肯定会有所不同 此时我们就面临着分类标准不相同时的转化问题 如果两种分类方法中存在包含关系, 即一种分类方法里面的某类食品包含另外一种分类方法里的两种或者多种食品, 则可以把划分详细的食品分类方法中对应的几种食品随机变量相加, 就可以转换到另外一种分类方法的食品中.

另外比较常见的情况是两种分类方法中不存在包含关系 这时, 我们将其看成是这样的理论问题: 把按照两种不同的方法分类得到的某类食品看成是多个随机变量的并集, 然后用这两种分类下所得的调查结果更好的估计此类食品的概率密度函数 因为虽然两种分类方法是不一样的, 但我们有理由相信每一种分类方法都是比较合理的, 这意味着这两种分类方法的差别不会太大, 如图 15 所示 基于以上考虑, 我们这里假设两种分类方法得到的概率密度函数服从同一分布, 区别只是它们的参数不同 现在的问题转化为, 已知服从同一分布参数不同的两个随机变量, 求其两个随机变量所表示的并集总体的分布




图 15 两种不同的分类方法之间的关系示意图




图 16 基于样本组合的的随机变量总体的分布估计

假设两种分类方法所对应的随机变量 x 和 y 的分布分别为 $f_x(x)$ 和 $f_y(y)$, 则我们可以根据已经建立的 x 和 y 的概率密度函数 $f_x(x)$ 和 $f_y(y)$, 得到两组分别服从分布 $f_x(x)$ 和 $f_y(y)$ 的随机样本 $\{x_1, x_2, \cdots, x_n\}$ 和 $\{y_1, y_2, \cdots, y_n\}$; 将样本 $\{x_1, x_2, \cdots, x_n\}$ 和 $\{y_1, y_2, \cdots, y_n\}$ 组合起来, 就可以形成更大的样本 $\{x_1, x_2, \cdots, x_n, y_1, y_2, \cdots, y_n\}$; 将样本 $\{x_1, x_2, \cdots, x_n, y_1, y_2, \cdots, y_n\}$ 看成是要估计的随机变量的样本, 则我们就可以用前面给出的多种算法(包括有参估计和无参估计等方法) 来估计随机变量的分布

总结起来我们给出的算法是:

Step 1 确定随机变量 x 和 y 的分布 $f_x(x)$ 和 $f_y(y)$;

Step 2 根据的 x 和 y 的概率密度函数 $f_x(x)$ 和 $f_y(y)$, 生成两组分别服从分布 $f_x(x)$ 和 $f_y(y)$ 的随机样本 $\{x_1, x_2, \dots, x_m\}$ 和 $\{y_1, y_2, \dots, y_n\}$, 其中样本数目按照调查时所确定的样本总数(或者与其成比例);

Step 3 样本数 $\{x_1, x_2, \dots, x_n\}$ 和 $\{y_1, y_2, \dots, y_n\}$ 组合起来, 生成总体样本 $\{x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_n\}$;

Step 4 由总体样本 $\{x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_n\}$ 估计随机变量的概率密度函数

为了验证我们所给的算法的性能, 我们进行了仿真 在前面我们已经证明食品摄入量模型服从正态分布, 所以这里我们选择以正态分布为例 假设在一种分类标准下, 抽样的样本总数为 5000, 抽样调查得出的概率密度为 $Nom(270, 258)$; 而在另外一种分类标准下, 用本总数为 15000, 估计出的概率密度分布为 $Nom(290, 178)$, 用总体样本估计分布时, 我们选择曲线拟合的方法 仿真结果如图 16 所示 估计出的均值为 286 1402, 方差为 173 4682

6 小 结

论文主要建立了膳食暴露评估数学模型, 主要是人群食物摄入量模型、污染物分布模型、风险评估模型三部分, 并对建模过程中的一些理论和实际问题进行了探讨 针对膳食暴露评估数学模型的特点, 提出了几种解决相应问题的算法, 例如怎样根据随机变量取值大于某一值的部分统计数据估计出随机变量(或向量)的概率分布函数; 两个不配套的抽样调查数据用什么方法去衔接使用才能达到理想的效果; 调查数据中不相同的统计分类标准之间怎么转化; 用不同地区的检测数据估计全国的情况时, 两者概率密度函数分布不一致时的处理问题 我们从理论上在一定程度上找到了解决这些问题的方法, 但并未找到实际的检测数据对所给算法进行检验, 这将是今后需要研究的问题

参考文献

- [1] Ralph L Kodell, Seung-Ho Kang, James J Chen. Statistical models of health risk due to microbial contamination of foods[J]. Environmental and Ecological Statistical, 2002, 9(3): 259-271.
- [2] Edler L, Poirier K, Dourson M, Kleiner J. Mathematical modeling and quantitative methods[J]. Food and Chemical Toxicology, 2002, 40(2-3): 283-326.
- [3] Arie H Havelaar, Maarten J Nauta, Jaap T Jansen. Fine-tuning food safety objectives and risk assessment[J]. International Journal of Food Microbiology, 2004, 93(1): 11-29.
- [4] 俞纯权, 宋廷山. 山东省城镇劳动就业与社会保障抽样调查方案设计[J]. 数理统计与管理, 2005, 24(2): 14-19.
- [5] 孙玉环. 住房需求抽样调查方案设计及数据处理方法[J]. 统计与决策(理论版), 2007, 23(6): 140-142.
- [6] 王亚文. 肉及肉制品安全风险系数研究[D]: [硕士学位论文]. 山东泰安: 山东农业大学, 2006.
- [7] 杨丽, 朱运平. 国际食品法典委员会(CAC)食品与饲料分类标准研究[J]. 世界标准化与质量管理, 2006, 43(12): 36-37.
- [8] 刘森. 关于二维随机概率密度函数算法的一点补充[J]. 中央民族大学学报, 2006, 15(3): 246-247.
- [9] 杨义群. 抽样调查与抽样检查——理论方法与应用[M]. 北京: 学苑出版社, 1993.
- [10] 朱道元, 吴诚鸥, 秦伟良. 多元统计分析与软件 SAS[M]. 南京: 东南大学出版社, 1999.
- [11] 朱道元. 数学建模精品案例[M]. 南京: 东南大学出版社, 1999.

Research on Modeling and Improving Food Security System

XU E Yan-hong¹, CHEN Jian-jun², ZHANG Liang^{*}

(1. School of Integrated Circuit, Southeast University, Nanjing 210013, China)

(2. School of Information Science and Engineering, Southeast University, Nanjing 210096, China)

Abstract The mathematical model of safety security system is discussed in this paper, and various methods for modeling are presented. Several theoretical issues of improving model are investigated. Firstly, an effective method suited for sampling of food classification is proposed, and a food model is established based on the CAC food classification standards. Secondly, the pollution distribution model and the algorithm estimating the overall probability density function from a small number of sample data is presented, and the problem of estimating the overall distribution from different regions is solved. Thirdly, A model for risk evaluation is established, and the convergence of the nonmatched survey input data is discussed. A new method to estimate the 99.999% right quantile for the intake of pollutants is proposed.

Keywords food model; pollution distribution model; risk evaluation model; food security