

第七章 竞赛择优问题

王 强

北京应用物理与计算数学研究所

提 要

数学教育的目标,是培养学生运用基础知识解决科技发展和生产实践中的问题.教育目标的实现程度,是要经过测量和评价的.

数学建模竞赛中产生的大量答卷或论文,以数学形式全面而深刻地反映出教育工作的质量.如何评阅和择优,则是各类赛事中最为难于处理的.

本章介绍 1996 年美国大学生数学建模竞赛 B 题及其相关情况,力求对三份优秀答卷加以比较.此外,简略说明中国和美国在竞赛择优问题上的实际操作情况.

§ 7.1 问题和背景

7.1.1 问题的提法

在确定像数学建模竞赛这种形式的比赛的优胜者时,常常要评阅大量的答卷,比如说,有 $P=100$ 份答卷.一个由 J 位评阅人组成的小组来完成评阅任务,基于竞赛资金对于能够聘请的评阅人数量和评阅时间的限制,如果 $P=100$,通常取 $J=8$.理想的情况是每个评阅人看所有的答卷,并将它们一一排序,但这种方法工作量太大.另一种方法是进行一系列的筛选,在一次筛选中每个评阅人只看一定数量的答卷,并给出分数.为了减少所看答卷的数量,考虑如下的筛选模式:如果答卷是被排序的,则在

每个评阅人给出的排序中排在最下面的 30% 答卷被剔除；如果答卷被打分（比如说从 1 分到 100 分），则某个截止分数线以下的答卷被剔除。这样，通过筛选的答卷重新放在一起返回给评阅小组，重复上述过程。人们关注的是，每个评阅人看的答卷要显著地小于 P 。评阅过程直到剩下 W 份答卷时停止，这些就是优胜者。当 $P=100$ 时通常取 $W=3$ 。

你的任务是利用排序、打分及其他方法的组合，确定一种筛选模式，按照这种模式，最后选中的 W 份答卷只能来自“最好的” $2W$ 份答卷（所谓“最好的”是指，我们假定存在着一种评阅人一致赞成的答卷的绝对排序）。例如，用你给出的方法得到的最后 3 份答卷将全部包括在“最好的”6 份答卷中。在所有满足上述要求的方法中，希望你能给出使每个评阅人所看答卷份数最少的一种方法。

注意在打分时存在系统偏差的可能。例如，对于一批答卷，一位评阅人平均给 70 分，而另一位可能给 80 分。在你给出的模式中如何调节尺度来适应竞赛参数(P , J 和 W)的变化？

7.1.2 问题的背景

这个问题，反映着数学建模竞赛中答卷排序工作的实际困难以及对解决办法的需要。为了改进工作，明白无误地在向莘莘学子求计求谋。诚如 Bell Labs 的 V. B. Mendiratta 所说，这是一个富有挑战性的现实问题。自然，它的应用也会扩展到诸多领域的决策方面。

在中国，全国数学建模竞赛历经数年，业已走上良性循环的道路。评阅答卷的工作是分为赛区和全国两级进行的，这更是加重了其复杂程度。如何确保评阅工作的公正性和科学性，一直是一个受到多方面关注和不断讨论研究的课题。在以往的竞赛中，评阅人深入细致地分析赛题并理解和把握它的各种解法，从而形成较为一致的判分标准。这是一条关键性的成功经验。其次，便

是依靠评阅人的公正与求实精神。在管理工作方面，也应当具备与此相适应的一套切实有效的办法。

评阅过程显示出，评阅人往往会对适合其业务倾向的答卷给出较高分数，反之则较低，这是一种系统误差；评阅人也会由于某种因素的影响而判分偶然偏高或偏低，这是一种偶然误差。然而，从数学上界定这两种真实存在的误差是困难而模糊的。再者，如何理解题目假定的“绝对排序”？如何在开始几轮筛选中保护 $2W$ 个“最好的”答卷不被筛除？这一切似乎也是无章可循的。

基于上述情况，我们选择具有典型意义的三份答卷，从如下两个方面加以介绍：第一，如何完成题目所给的基本任务；第二，怎样分析评阅人的判分误差。

7.1.3 竞赛结果

在参赛的 393 个队中有 267 个队选择了本题，结果有 5 个队获得了特等奖，38 个队获得一等奖，77 个队获得二等奖。获得特等奖的 5 个队分别来自复旦大学，Gettysburg 学院，St. Bonaventure 大学，中国科技大学和 Washington 大学。我国华东科技大学、信息工程学院、国防科技大学、华南科技大学、西安电子科技大学和浙江大学共六个队获得一等奖。

7.1.4 本章其余各节的安排

在 § 7.2，§ 7.3 和 § 7.4 中，我们分别介绍复旦大学，Gettysburg 学院和中国科技大学三个队的优秀论文；在 § 7.5 中我们对其余二篇优秀论文作一概述；在 § 7.6 中对两位评阅专家的意见进行归纳。

§ 7.2 基于模拟分析的论文优选方案 ——复旦大学优秀获奖论文(答卷)

这份答卷共建立五个模型：理想模型，圆桌模型，传统模

型, 筛除模型和高级圆桌模型. 在这些模型之间, 彼此略有逻辑关联. 此处, 我们仅引用具有代表性的高级圆桌模型.

在答卷的假设条件中, 认为存在着评阅人一致同意的绝对的排序和判分, 而且其判分服从正态分布 $N(70, 100)$. 其次, 认为评阅人在判分过程中会出现偶然误差和系统误差. 再者, 明确指出, 题目所要求的“最后 W 份优胜答卷只能来自‘最好的’ $2W$ 份答卷”是一个概率事件.

这个模型使用排序和判分相结合的方法. 在最后一轮筛选之前, 评阅人对每组答卷排序而且组与组之间部分地交换答卷, 依此反复, 以求实现筛除 30% 最下面答卷的题目要求. 这个筛选方案结构稳定而且易于执行. 每轮中对答卷交换次数的设定使整个过程相当灵活. 在最后一轮, 利用答卷平均分来确定优胜者.

1. 把答卷平均分配给每位评阅人. 在每一轮中筛除比例取为 30%. 在 n 轮筛选之后, 每位评阅人仅留下一份答卷. 后面会说明, 一旦给定评阅人的能力参数, 我们可以确定在每轮中的交换次数 K_i .

对于本题 $n=6$, 每轮之后每位评阅人留有的答卷份数为 9, 6, 4, 3, 2 和 1. 每轮中筛除答卷的份数为 4, 3, 2, 1, 1 和 1.

2. 评阅人围着圆桌就坐. 设 $K_i = i$ (随后我们充分讨论选择 K_i 值的方法). 在第一轮中, $K_0 = 0$, 评阅人不交换答卷只是给它们排序并筛除最差的 30%.
3. 在第二轮中, $K_1 = 1$. 每位评阅人把最差的 30% 答卷向右传. 之后, 每位评阅人为得到的新答卷判分而且为所有答卷 (包括未经传递者) 重新排序, 而后筛除最差的 30%.
4. 对于 $K_i \geq 2$, 向右传、判分, 再排序和筛出最差的 30%, 这组步骤进行 K_i 次.
5. 当每位评阅人只有一份答卷时, 答卷已被分发和评阅过 n 次. 从 n 个判分的平均值中, 我们选取最好的三份答卷作为优胜者.

为什么要交换最下面的 30% 答卷呢？题目的要求是，每位评阅人可以筛除最下面 30% 的答卷，此处给出的是一个限度。评阅人会依据自己手中答卷的优劣情况自行决定（在限度内）筛除量，这导致方案的复杂化和不稳定。我们的办法是为评阅人手中较差答卷提供流通、比较和再评阅机会。例如，考虑一份已由 J_1 传给 J_2 的最下面 30% 的答卷。如果在 J_2 重新排序后，它依然属于 J_2 手中答卷最下面的 30%，则它确应被筛除；如果 J_2 的最下面 30% 答卷中包含不是来自 J_1 的答卷（仅由 J_2 排序），则筛除它也不会破坏 30% 的限度。

每轮中传递答卷多少次？首先，我们注意 $\{K_i\}$ 的两个性质：

1. $\{K_i\}$ 是有界的，即， $0 \leq K_i < J$ 。
2. $\{K_i\}$ 是单调上升的，即， $i < j \Rightarrow K_i \leq K_j$ 。

只有 J 位评阅人，而且所有答卷分成了 J 组。当 $K_i \geq J$ 时，评阅人会发现先前传递出去的答卷又回来了。所以 $K_i < J$ 。

在最后的几轮中，优秀答卷（顶级的 6 份答卷）似乎更易于被筛除，应逐步增加每轮的传递次数，所以 $\{K_i\}$ 是单调上升的。

其次，在 $\{K_i\}$ 和花费 C 之间存在依赖关系。也就是， C 是随着所有评阅人排序过的答卷总数 K 而单调上升的， $K = 8 \sum_{i=0}^n P_i K_i + 100$ ，此处 P_i 是在第 i 轮筛除答卷的份数。在这个模型中，每位评阅人阅读答卷的数量几乎是相等的，所以 C 随着 K 单调上升。

显然，阅卷花费和筛选方案的精度是相互矛盾的：花费越少，产生不合格优胜者的概率就越大。我们也可以从其相应的 C 为最小的 $\{K_i\}$ 开始，通过按顺序逐一地试验 $\{K_i\}$ ，我们一步步增加花费，与此同时也增加了方案的精度。当精度适合要求时，由这组 $\{K_i\}$ 相应的方案就是最佳方案。我们可以利用下面要谈的模拟程序来检验一个方案的精度。

花费函数 减低评阅人评阅答卷数量是为了节省开支，不同评阅人评阅数量应尽可能相等。花费函数取决于实际情况，我们

采用如下形式：评阅 1 至 20 份答卷则每份 m 元，21 至 50 份则每份 $2m$ 元，而 51 至 100 份则每份 $4m$ 元。于是

$$C = m \sum_{i=1}^J \{a_i + (a_i - 20)u(a_i - 20) + 2(a_i - 50)u(a_i - 50)\},$$

其中 a_i 是第 i 位评阅人评阅答卷的份数且

$$u(x-a) = \begin{cases} 0, & x < a; \\ 1, & x \geq a. \end{cases}$$

花费函数的微小变化对于筛选方案仅有微小影响。此处取 $m = 10$ 。

评阅人 初步模拟显示，评阅人的能力是确定筛选方案的最重要因素。我们使用两个参数来描述评阅人的能力：

- 判分偶然误差的方差。方差越小，表明评阅人的经验越丰富而且判分越精确，反之亦然。这个方差可由该评阅人的以往工作效能得到。
- 系统偏差的量度。在现实生活中，把个人偏差量化是困难的。所以，我们把问题简化而把评阅人和答卷分为三种类型：激进的，中立的和保守的。一位激进评阅人对激进答卷给高分而对保守答卷给低分，对于中立答卷没有偏差。一位保守评阅人的情况则相反。中立评阅人则完全没有偏差。

模拟算法 下面给出对评阅人判分过程的模拟：

1. 生成 100 个服从 $N(70, 100)$ 分布的界于 1 至 100 之间的随机整数。把它们作为答卷的“真实”分数放入数组 `paper-score[1, i]`。
2. 取定常数 d 作为全体评阅人偶然误差的上界。生成 8 个随机整数 d_j 作为评阅人偶然误差的标准差，使之在 0 至 d 之间呈离散均匀整数分布，并把这些数放入数组 `judge[1, j]` 中。
3. 取定常数 $e > 0$ 作为系统偏差值。设 1, 0, -1 分别代表激进，中立和保守。给每份答卷一个取自 $\{1, 0, -1\}$ 的数并放入数组 `paper-score[0, i]`。给每位评阅人一个取自 $\{1, 0, -1\}$ 的

数并放入数组 $\text{judge}[0, j]$. 我们用

$$s = e \cdot \text{paper-score}[0, i] \cdot \text{judge}[0, j]$$

来计算系统偏差 s . 例如, 一位保守评阅人遇到激进答卷, 则 $s = -e$.

4. 评阅人 j 为答卷 i 判分的模式: 设

$$u = \text{paper-score}[1, i] + s.$$

在区间 $[1, 100]$ 中按正态分布 $N(u, d_j^2)$ 生成随机整数并放入数组 $\text{judge-score}[i, j]$. 这样, 我们就可以生成评阅人的判分矩阵.

对参数 d 和 e 的处理方法 从概率论知识可以得到

引理 设 $X_1, X_2, \dots, X_n$ 是分别具有方差 $\sigma_i^2 (i=1, 2, \dots, n)$ 的独立随机变量, 则 $\bar{X} = \sum X_i/n$ 的方差是

$$\sigma^2 = \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2.$$

于是, 有如下推论:

推论 1 $\frac{1}{\sqrt{n}} \min_{1 \leq i \leq n} \{\sigma_i\} \leq \sigma \leq \frac{1}{\sqrt{n}} \max_{1 \leq i \leq n} \{\sigma_i\}.$

由此我们知道, 在高级圆桌模型的最后一轮中, 对每份答卷采用其平均分排序确实能够提高评阅过程的精确度.

利用 Cauchy 不等式, 可以得出

$$\sigma^2 \geq \frac{1}{n^3} \left(\sum_{i=1}^n \sigma_i \right)^2,$$

从而有

推论 2 $\sigma \geq \frac{1}{\sqrt{n}} \frac{\sum_{i=1}^n \sigma_i}{n}.$

作者进一步假定 σ 在 $[0, d]$ 上呈现离散均匀分布, 从而

$$\frac{\sum_{i=1}^n \sigma_i}{n} \approx \frac{d}{2}.$$

对于 $n \leq 8$, 这就得到平均偶然误差的标准差估值:

$$\sigma \geq \frac{1}{2\sqrt{2}} \frac{\sum_{i=1}^n \sigma_i}{n} \approx \frac{\sqrt{2}d}{8}.$$

此外, 经过大量的计算机模拟, 作者发现如下的规律:

$$d < 10.$$

而且也知道, d 对结果影响巨大, 而 e 的作用则是很小的. 自然, 可以把 d 和 e 取为同样的量级. 计算机模拟是工作基础, 对 d 和 e 的不同取值来寻找最优方案.

模拟实践表明, 取 $e \in \{0, 5, 10\}$ 和 $d \in \{1, 3, 5, 7, 9\}$ 是适当的.

表 7-1 参数选取和失败率

偏差 e	最大方差	K_n	失败率(%)
0	5	1,1,1,1,1,2,4	1.8
	7	1,1,1,1,1,4,5	3.9
	9	1,1,1,2,2,4,5	4.8
5	5	1,1,1,2,2,2,4	0.7
	7	2,2,2,2,2,4,8	2.7
	9	2,2,2,2,2,4,8	6.7

由上述可知, 高级圆桌模型的操作步骤清楚, 易于理解和投入实际应用. 对于给定的参数 P , J 和 W , 该模型首先就要求出最优的每轮交换次数 $\{K_i\}$. 无庸讳言, 优化 $\{K_i\}$ 是消耗计算机资源的.

在这个模型中, 由于它的筛选机制和参数优化, 评阅人的答卷评阅量是很低的. 这是一个相当突出的优点.

对于 P , J 和 W 的不同取值, 作者对本模型进行了稳定性检验; 并且相应于题目中所给的一组数据, 找出了最优筛选方案, 其中, 总阅读量应低于 170, 失败率为 3%.

§ 7.3 论文评阅的优化模式

——Gettysburg 学院优秀获奖论文

这份答卷的假设条件很是细致, 考虑了评阅中几种实际情

况. 在对答卷的假设中, 认为存在绝对排序; 另外, 答卷份数远远多于优胜者个数. 在对评阅人的假设中, 认为评阅人要有能力解决提出的问题; 评阅人有自己对于答卷内容的偏好, 评阅工作是在某种误差界限内进行; 评阅人每次坐下来至多能公正地评阅 20 份答卷; 要有首席评阅人, 他只负责仲裁歧见和在最后一轮投票; 评阅人至少要有五位, 其中包括首席评阅人.

常数和术语的定义:

P : 答卷总份数.

J : 评阅人总数, 不包括首席评阅人.

J_k : 代表第 k 位评阅人.

W : 优胜者总数.

read: 一位评阅人一次评阅一份答卷.

round: 一个筛除过程, 把一组答卷筛剩 W 份.

R_a : 代表第 a 轮.

S_a : 在第 a 轮中堆数. 一堆是一组份数少于 P 的答卷.

N : 在一堆中的答卷份数.

S_{jk} : 代表 k 轮中的 j 堆.

error: 与绝对排序相矛盾的一位评阅人的排序.

评阅前准备工作 我们首先确定第一轮所需要的堆数 S_1 . 为保证对称的筛选, 我们需要 S_1 是 2 的方幂. 由我们的假定, 每位评阅人一次至多可以读 20 份答卷, 所以每堆的份数不能超过 20. 在每堆中的答卷份数是 $N = P/2^n$, 此处 n 是满足

$$N = P/2^n \leq 20$$

的最小值. 如果 2^n 不整除 P , N 向上加一. 答卷尽可能均匀地分成 S_1 堆. 我们给每位评阅人发一堆. 如果最后剩下答卷, 某些评阅人将被要求重复第一轮的操作.

第一轮 评阅人 J_1 和 J_2 分得 S_{11} 堆和 S_{21} 堆. 评阅人 J_i 从 S_{i1} 堆中选择 W 份答卷, 以便保证最好的 W 份答卷不会在 R_1 轮中筛除. 选好后, 他们再把手中的堆交换. 于是, 评阅人 J_1 从

S_{21} 中筛选 W 份, 而 J_2 从 S_{11} 中筛选 W 份. 尔后, 他们共同比较两次评阅的答卷排序进而由 S_{11} 和 S_{21} 的合并中选出 W 份答卷来. 如果存在争论, 由首席评阅人决定提交哪份答卷. 依此办法每两个堆都筛选出 W 份答卷. 第一轮完成时, 有 $S_2 = 2^{n-1}$ 个堆, 而且每堆有 $N = W$ 份答卷.

中间轮 将有 $n-2$ 个“中间轮”. 在第 r 轮 R_r 开始时, 有 $S_r = 2^{n-r-1}$ 堆和 $N = W$ 份答卷. 操作方法与前相似, 比如, 把 S_{1r} 和 S_{2r} 分给两位未曾经手过的评阅人. 每位评阅人都从 S_{1r} 和 S_{2r} 的合并中选出 W 份答卷, 而后再共同确定 W 份答卷向上提交. 首席评阅人解决任何歧见问题. 其他堆也如此处理. 这个过程逐轮重复直到 $n-1$ 轮 R_{n-1} , 这轮完成时, 便只剩下 $2W$ 份答卷.

决胜轮 最后一轮 R_n 是投票过程. 为了保证公正性并考虑到决胜的重要性, 推选包括首席评阅人在内五位评阅人来评价各答卷. 这些评阅人评阅剩下的 $2W$ 份答卷并且排序. 一位官方的可能是附加的评阅人记票. 得票数排在前面的 W 份答卷就是优胜者. 如果出现票数相同而难分胜负, 首席评阅人投票解决.

人的因素 一个不能控制的变量是人的因素. 作者用描述评阅人行为方式的概率分布来模拟人的因素. 每位评阅人对答卷内容持有偏好. 最普通的例子是, 一位评阅人把形式看得比内容重要, 而另一位评阅人却更侧重后者. 这样, 两份答卷的排序就可能颠倒. 此处, 用 d 表示在绝对排序尺度下两份答卷的距离. 作者进而选择函数

$$E(P, d) = \frac{1.46 + \arctan(1 - 60d/P)}{2.92 + \frac{\pi}{2}}$$

作为一位评阅人对两份答卷的排序不同于绝对排序的概率, 此处 P 表示竞赛中答卷的总份数. 作者指出, 随着两份答卷的距离增大, 错排的概率迅速下降. 当两份答卷的距离为 $0.01P$ 时, 错

排的概率近似于 50%。所以，对于 $P=100$ 在答卷 5 和答卷 6 之间选择完全是随机的。而当距离大于 $0.17P$ 时，错排概率为零。距离界于 $0.01P$ 和 $0.17P$ 之间的错排概率值正是真实情况的表达——两份答卷越接近，评阅人对答卷风格的个人偏好越可能影响它们的排序。类似地，两份答卷分离越远，评阅人的偏好很少会影响对它们的比较。

作者指出，对人的因素建模是困难的。上述函数是本文对人的本性的最佳估计。没有数据可供参照，以便搞清楚在这些环境下人们实际上是如何动作的。

部分结果 不包括首席评阅人的仲裁工作，经过 n 个筛选轮后，总的阅读量是

$$2P + \sum_{i=2}^{n-1} 2^{n-i+2}W + 5 \cdot (2W).$$

其中，第一项是在 R_1 中的阅读数，第二项考虑 R_2 到 R_{n-1} ，第三项用于最后一轮 R_n 。

这个模型的失败概率特别低，通常小于 0.1%。但它的总阅读量是比较大的，以题目所给数据为例，总阅读量为 254。

§ 7.4 快速选择优胜者

——中国科技大学优秀获奖论文

在这份答卷的假设条件中，认为存在一种客观准则以判定两份答卷的优劣次序，而且这种排序具有传递性。由此可见，作者认为存在全部答卷的绝对排序。

其后，作者给出了简明的问题分析和符号系统。通常，在评阅中使用排序和判分两种方法。在判分方案中可能存在系统偏差，也就是，每位评阅人在判分中可以有主观倾向，这导致不同评阅人所判分数的不可比较性。不过有理由相信，同一位评阅人对不同答卷的判分是可比较的，即使是取自不同的筛选轮中。所以，同排序法相比，为了在早期筛选轮中记录评阅结果，判分是

更加有意义的方式。作者采用判分方案，因而同一位评阅人不必重读一份答卷。此处应注意的是，不直接比较不同评阅人的判分，而主要是利用判分来获得排序。

作者指出，在判分过程中存在偶然发生的“误判”，也存在评阅人之间系统性的主观差异。

表 7-2

符 号

记号	含 义
P	答卷总份数
W	优胜者人数
J	评阅人总数
T	总评阅时间
P_i	答卷 i
$P_{(i)}$	具有绝对排序 i 的答卷
S_i	答卷 i 的绝对分数
$P_i > P_j$	答卷 i 在绝对排序下优于答卷 j
R_i	当前已知优于 P_i 的答卷份数
ORD	表达每两份答卷间已知关系的矩阵
$[x]$	不小于 x 的最小整数
$N(\mu_0, \sigma_0^2)$	具有均值 μ_0 和标准差 σ_0 的正态分布
σ_i	评阅人判分的标准差
μ_j, σ_j	评阅人 j 判分的均值和标准差
$\bar{\mu}_j, \bar{\sigma}_j$	μ_j, σ_j 的估值
Perror	发生误判的概率

评阅答卷的过程 作者简明扼要地介绍了对于评卷过程的设计：

- 把评阅过程分为若干个筛选轮，而且在每轮中遵从下述原则直到剩下 W 份答卷。
- 采用判分方案。
- 不比较相异评阅人的判分。
- 在第一轮中，把答卷平均分给所有评阅人。判分后，从每组中选出上方 $2W$ 份答卷而进入下一轮。

- 在每轮结束时,计算每份答卷上方的答卷份数(称之为该答卷的当前等级),之后筛除其当前等级多于 $W-1$ 的每份答卷.
- 在每轮开始时,尽可能把当前等级相近的答卷分给同一位评阅人.
- 每位评阅人在每轮中分得答卷的份数应尽可能相同.

在上述操作中,作者利用矩阵 ORD 来描述已知的答卷排序.其定义为

$$\text{ORD}_{ij} = \begin{cases} 1, & \text{如果 } P_i > P_j; \\ -1, & \text{如果 } P_j > P_i; \\ 0, & \text{如果 } P_i = P_j; \\ \infty, & \text{如果 } P_i \text{ 和 } P_j \text{ 没经评阅人比较.} \end{cases}$$

在每轮开始时,总是把答卷分给评阅人而由评阅人给每份答卷判分.而后,在完成的各轮中找出由同一位评阅人判分的 P_i 和 P_j 并且填充 ORD_{ij} 和 ORD_{ji} .此外,还要用 ORD 的传递闭包来代替 ORD,简言之,就是把所有由 ORD_{ij} 得到的非直接答卷排序加到 ORD 矩阵中去.依据这个矩阵就可以计算一份答卷的当前等级.

考虑误判 误判指的是最后 W 份答卷不是最好的.如果最后 W 份答卷不是完全属于最好的 $2W$ 份,则发生了误差.

假定,对于一份具有绝对分数 μ_1 的答卷,某位评阅人的判分是遵从正态分布 $N(\mu_1, \sigma_1^2)$ 的一个随机数.误判来源于评阅人判分对于绝对分数的偏差.

必然存在所有答卷绝对分数的一个分布,假定它是正态分布 $N(\mu_0, \sigma_0^2)$,从而,比值 σ_1/σ_0 就反映评阅人辨别答卷质量的能力.给定 P, J, W 和 σ_1/σ_0 ,就可以利用基本模型来估计误差出现的概率 P_{error} .如果这个概率充分小,我们就可以期望该模型提供令人满意的结果.

矩阵 ORD 的精度是可以改善的.例如,要确定 P_i 和 P_j 的实际排序,只须找到同时读过这两份答卷的评阅人的判分,比较

两个判分之和就能确定新的 ORD_j 。

对误判概率的粗估和观察 下列两个模拟是根本性的：

- 模拟绝对分数的分布。一般地说，有理由采用一个正态分布。为指定 100 份答卷的分数，可在 0 到 100 之间生成遵从 $N(60, 30^2)$ 的 100 个随机数。
- 模拟对一份答卷的判分。通过在该答卷的绝对分数上添加一个正态随机数来模拟一位评阅人的判分。

比值 σ_1/σ_0 应是相当小（比如， ≤ 0.1 ），因为评阅人应精于评阅。在我们的模拟中取 $\sigma_1/\sigma_0 = 1/30, 2/30$ 和 $3/30$ 三种情形。

作者也对这些情形从理论上估计了最差环境中的误判概率 P_{error} 。当 $P_{(7)}, P_{(8)}, \dots$ 之中的一份或多份答卷进入最后的三份优胜卷，误差便发生。 $P_{(7)}$ 进入最后三份的概率在 P_{error} 中所占份额最大。设 $P_{error}(i, j)$ 为误判答卷 i 和 j 的概率。作者通过 $P_{(7)}$ 进入最后三份的概率来近似表示 P_{error} ：

$$\begin{aligned} P_{error} &\approx \frac{1}{8} P_{error}(3, 7) \\ &\quad + \left(\frac{1}{8}\right)^2 \sum P_{error}(3, i) P_{error}(i, 7) + \dots \\ &\approx \frac{1}{8} P_{error}(3, 7) \\ &\quad + \left(\frac{1}{8}\right)^2 \sum_{i=4}^8 P_{error}(3, i) P_{error}(i, 7). \end{aligned}$$

模拟结果与理论估计一致。

表 7-3 数值实验的结果与理论估值

$P=100, J=8, W=3$

σ_1/σ_0	Errors	观察 P_{error}	P_{error} 粗估
1/30	0	.000	10^{-7}
2/30	0	.000	.0006
3/30	4	.004	.004

评阅人之间的系统偏差 当考虑到不同评阅人判分倾向的差别时，在第一轮中由每位评阅人选出相同数量的答卷就不是好办法，因为很可能在第一轮就把优秀的答卷筛除。

另一种代替办法是，当第一轮评阅结束时，把每组答卷的判分输入计算机，它会给出每位评阅人参数(平均分和标准差)，而且会相应于一个确定的绝对水平对每组答卷计算出用于筛除答卷的分数界限。按这个办法，优秀答卷很少可能在第一轮被筛除。对所有评阅人参数的估值使我们能够在某种程度上比较来自不同评阅人的判分。

我们利用 Bayes 估计来确定评阅人 j 的参数 (μ_j, σ_j) 的估值。假定评阅人 j 给答卷 $P_1, \dots, P_n$ 的判分是 $S_1, \dots, S_n$ 。我们采用最大似然法来估计 σ_j ：

$$\hat{\sigma}_j^2 = \frac{1}{n} \sum [S_i - E(S_i)]^2.$$

之后，再利用 Bayes 方法估计 μ_j 。事实上，我们可能有关于每位评阅人判分倾向的先验知识。即使没有，我们依然有理由假定一个评阅人判分的先验分布。如果其先验参数是 (μ_0, σ_0^2) ，那么后验参数就是

$$\hat{\mu}_j = \frac{n \cdot E(S)}{n + \left(\frac{\hat{\sigma}_j}{\sigma_0}\right)^2} + \frac{\left(\frac{\hat{\sigma}_j}{\sigma_0}\right)^2 \cdot \mu_0}{n + \left(\frac{\hat{\sigma}_j}{\sigma_0}\right)^2}.$$

这样，我们就能把分位数 $(N(\hat{\mu}_j, \hat{\sigma}_j^2), \text{LEVEL})$ 用作判分界限，此处， $1 - \text{LEVEL}$ 是应被保留的答卷的预期份额。一个适当的取值是

$$\text{LEVEL} = 1 - \frac{W \cdot J}{P}.$$

若干建议

- 适当减少在第一轮中筛除答卷的份数，会降低错判概率。
- 在每一轮中按需要改变筛除份数，有助于在竞赛中确定不同

层次的参赛者。

- 为了切合实际和高效率，建议首先预评答卷，也就是，筛除明显低质量答卷。
- 在各个筛选轮中间，评阅人进行若干讨论以使大家获得有关答卷整体水平的知识。这样的反馈机制肯定有助于降低评阅的标准差。
- 当剩下 $2W$ 份左右答卷时，如果时间允许的话，所有评阅人应汇集在一起共同阅读留下来的答卷，以便尽可能准确地选出顶级的 W 份答卷。

对模型的检验 作者通过改变 P , J , W 的值来检验模型稳定性。从中发现，当 W/P 过于小（比如， $<1/100$ ）时，本模型不能很好工作，不过适当减少在每轮中筛除答卷的份数，会使误差概率 P_{error} 降低。对题目所给基本模型的模拟计算是成功的。作者还运用具有随机生成的均值和方差的正态分布来模拟不同评阅人的判分，结果是，随着 LEVEL 上升，总的评阅时间下降，但发生更多的误差。

§ 7.5 其余模型简介

7.5.1 St. Bonaventure 大学的模型

这个模型的工作基础是把问题分为四个主要方面并分别加以处理：在评阅人中间分发答卷、打分的办法，每轮淘汰答卷的数量以及总的评阅轮数安排。

在评阅进程中，着重于维持公正性和所有评阅手续的灵活处理。在每轮中筛除尽可能多的答卷，使总的评阅轮数降到最低，而且最重要的是，要使上述各个要点均衡地实现。

本模型假定，预算资金只影响评阅人的数量。而且还假定在评阅人中间存在一个近似的“绝对排序”系统，也就是，如果每位评阅人对所有答卷打分或排序，那么，诸位评阅人的结果会基本

上一致，仅在一些地方答卷相邻顺序有颠倒。

7.5.2 Washington 大学的模型

作者指出，这个模型充分健壮，不管在评阅过程中随机误差和系统误差如何，保证筛选出真正优秀的答卷。该模型引入评阅过程中的不协调性，也就是把实际的答卷得分表示为固有分数、评阅人系统偏差和误差项之和：

$$S_{jp} = S_p + B_j + \epsilon_{jp}.$$

本模型利用计算机指引下的迭代处理来确定评阅手续。在每轮评阅之后，计算机程序利用偏差估计为每份答卷计算出其固有分数的置信区间。这些置信区间用于筛除尽可能多的答卷，与此同时，在指定的置信水准上保证顶级 W 份答卷提交到下一轮。

作者就一系列参数值进行了计算机模拟并给出结论：固有分数服从均值 50 和标准差 20 的正态分布，偏差和协调性参数则是变化的。

本模型的特色是导出了若干解析结果，并用于评阅过程中。这个成绩的基础是如下的假定：答卷的固有分数、所有评阅人的系统偏差范围以及评阅人的随机偏差均服从正态分布，而且，正态分布中的均值和标准差是可以在评阅过程中近似获得，其误差认为是可忽略的。

§ 7.6 来自评阅专家的评论

竞赛择优问题也应用于其他决策领域，例如，奖学金的发放，或者在众多申请者中为一个特定职位进行筛选。在这种情形下，决策人或评阅人就必须以某种方式甄别申请者以求确定谁是“最优”。而且，这些决定要在时间限制下作出，就使得每位决策人不可能去评价所有申请者；即便可能，各种评价也难得完全一致。正是这个特征使竞赛论文的评阅工作复杂起来。

关于绝对排序的假定 (There is an absolute rank-ordering to which all judges would agree) 使问题貌似简单, 实际上是一个陷阱, 对形形色色的论文产生影响. 有些论文假定绝对排序而对基本问题提供了启发式解法; 更有些论文明知该假定不真实却依然用它建模, 因为这是题目所要求的. 另外一些使用这个假定的论文明显地不相信它, 论文中发展了更复杂的算法而对“绝对排序”予以摒弃. 还有若干论文试图运用图论命题乃至模糊集合概念等等理论来改进这个问题. 数学建模实践表明, 不切实际的假定会使模型很少能有实用价值. 作为建模者, 应严格地审视问题的所有假定, 如有必要, 应改进问题使之具有真实性.

建模的问题不同, 在评阅过程中判定论文优劣的标准也是各异的. 就这个问题来说, 较好的论文应具备如下特征: 首先, 解决了基本问题; 更进一步, 便是完成一个具有适应复杂性的改进来精确建模, 而它的用法却是简单的; 再者, 每个模型叙述清楚, 并用例子展示用法.

更为理想的论文应能显示解法最优或接近最优; 应能适应不同的模型参数; 再进一步, 应能处理评阅人偏差, 把算法的成功率表示为评阅人偏差的函数并加以测量. 最后, 应能考查其他算法, 指明模型的优点和缺点等.

在本次评阅中, 获得特等奖的论文是基于如下特征脱颖而出: 第一, 对评阅人偏差的有效处理; 第二, 有助于实现模型应用的适当文档.

参 考 文 献

- [1] 戴忠恒:《教育统计、测量与评价》, 中国科学技术出版社, 1991年.

[2] 佟庆伟等: 《教育科研中的量化方法》, 中国科学技术出版社, 1997 年.

[3] Box, G. E. P. and Tiao, G. C. 1973. *Bayesian Inference in Statistical Analysis*. Reading, MA: Addison-Wesley.

[4] Wang, Yihe. 1986. *Introduction to Discrete Mathematics*. Harbin, China: Harbin Institute of Technology Press.

[5] DeGroot, Morris H. 1986. *Probability and Statistics*. Reading, MA: Addison-Wesley.